



מבוא למערכות לומדות (236756)

סמסטר חורף תשע"ט

מבחן מסכם מועד ב', 6 במרץ 2019

מספר סטודנט:

משך המבחן: 2.5 שעות. (150 דקות)

חומר עזר: אין להשתמש בכל חומר עזר. בעמוד הבא לרשותכם דף נוסחאות והגדרות.

הנחיות כלליות:

- המבחן כתוב בלשון זכר ומיועד לנשים ולגברים כאחד.
- מלאו את הפרטים בראש דף זה ובדף השער המצורף, בעט בלבד.
- במבחן 16 עמודים ממוספרים סהכ, כולל עמוד זה שמספרו 1. ודאו שיש לכם כל הדפים.
- במבחן 4 חלקים. יש לענות על כל השאלות.
- כל התשובות יכתבו על טופס הבחינה, ויש להחזירו בתום הבחינה.
- אנא כתבו בכתב יד קריא וברור. תשובה בכתב יד שאינו קריא לא תיבדק.
- נא לא לתלוש עמודים ממחברת הבחינה.
- נא לכתוב רק את מה שהתבקשתם ולצרף הסברים קצרים רק כפי שמבוקש בשאלה—אין צורך בהסברים או פרטים נוספים על אלו שהתבקשתם במפורש.

Less is More

בהצלחה!



דף נוסחאות

$$1. \binom{n}{k} \leq n^k$$

$$2. L_D^{01} = \text{true error} = \text{שגיאת הכללה}$$

$$3. L_S^{01} = \text{training error} = \text{empirical error} = \text{שגיאת אימון} = \text{שגיאה אמפירית} \quad (\text{השגיאות על מדגם})$$

$$4. L_D^{01} - L_S^{01} = \text{estimation error} = \text{שגיאת הערכה}$$

$$5. e \approx 2.72$$

$$6. \text{התפלגות גאומטרית עם פרמטר } p$$

$$P(x = n) = p (1 - p)^{n-1}$$

$$7. \text{תהא } H \text{ מחלקת היפוטזות של בעיית למידה כלשהי, ו- } S \text{ קבוצת אימון שנבחרת באקראי. נסמן}$$

$$\hat{h} = \operatorname{argmin}_{h \in H} L_D^{01}(h)$$

$$h = \operatorname{argmin}_{h \in H} L_S^{01}(h) \text{ אזי, לכל } \delta > 0: \text{ בהסתברות של לפחות } 1 - \delta \text{ מתקיים:}$$

$$L_D^{01}(\hat{h}) \leq L_D^{01}(h) + O\left(\sqrt{\frac{\operatorname{VCDIM}(H) + \frac{1}{\log(\delta)}}{|S|}}\right)$$

$$8. \text{מאפיין} = \text{feature}$$

$$9. \text{סיווג} = \text{label}$$

$$10. [x]_+ = \max(x, 0)$$

$$11. \text{מונום (monomial) במשתנים } x[1] \dots x[k] \text{ מדרגה } d \text{ הוא מכפלה מהצורה}$$

$$x[i_1] \cdot x[i_2] \cdots x[i_d] \text{ כאשר } i_1 \dots i_d \text{ הם בתחום } \{1..k\} \text{ (עם חזרות).}$$

$$12. \llbracket \text{תנאי} \rrbracket \text{ מוגדר כ- } I \text{ אם התנאי מתקיים, אחרת } 0.$$

$$13. \text{Decision stumps על ייצוג מאפיינים כלשהו } x[1]..x[k] \text{ הוא מחלקת היפותזות הכוללת}$$

$$\text{פונקציות מהצורה } h_{i,a} = \llbracket x[i] \geq a \rrbracket \text{ עבור } i=1..k \text{ ו- } a \text{ מספר ממשי כלשהו.}$$



חלק א : שאלות קצרות (30 נק')

1. פונקציית השגיאה הריבועית $L(\hat{y}, y) = (\hat{y} - y)^2$ מהווה פונק שגיאה Surrogate עבור

שגיאת ה 0-1

אמת ☒

שקר ☒

2. שגיאת ולידציה נמוכה מעידה תמיד על כך שהמודל יבצע באופן דומה על קבוצת המבחן

אמת ☐

שקר ☒

3. מקסימום של n פונקציות קמורות (ב R^d) היא פונקציה קמורה

אמת ☒

שקר ☐ דוגמא נגדית (חובה לספק במקרה שסימנתם "שקר"):

4. פונקציית המטרה של Soft-SVM היא $\lambda L_S^{hinge}(w) + \|w\|_2^2$

ככל שמגדילים את λ , כך צפוי ששגיאת האימון (יש לסמן אפשרות אחת):

תרד ☒

תעלה ☐

תישאר ללא שינוי ☐

5. אם מריצים אלגוריתם Halving (חצייה) במודל המקוון (on-line) על מחלקת היפותזה סופית,

במקרה ה Realizable, אז מספר השגיאות שנעשה הוא סופי

אמת ☐

שקר ☐



6. הסבירו מהו Feature Selection מסוג wrapper

7. עבור פריור (prior) קבוע על מרחב פרמטרים, ככל שמספר הדוגמאות גדל משערך MAP

בהכרח מתכנס למשערך MLE

אמת ☐

שקר ☐

8. אחרי מספר מספיק של איטרציות אלגוריתם AdaBoost יגיע לשגיאה 0 על קבוצת האימון

אמת ☒

שקר ☒



חלק ב: סיבוכיות של מחלקות היפותזה

הי \mathcal{H} מחלקת היפותזות בינאריות, מעל מרחב מדגם \mathcal{X} . תהי C תת קבוצה סופית של \mathcal{X} . לכל $h \in \mathcal{H}$ נסמן ב h_C את פונקציית ההגבלה (restriction) לקבוצה C , כלומר הפונקציה המוגדרת על התחום C ומזדהה עם הפונקציה h על תחום זה.

1. הגדירו בצורה מדויקת את פונקציית הגידול (growth function) $\tau_H: \{0,1,2 \dots\} \mapsto \{0,1,2 \dots\}$, כפי שנילמד בכיתה.

$$\tau_H(m) =$$

2. השלימו את ההגדרה של ניתוח (shattering) של קבוצה.

קבוצה $C \subseteq \mathcal{X}$ מנותצת (shattered) על ידי \mathcal{H} אם $\exists h \in \mathcal{H}$ קיימת $y_1, \dots, y_m \in \mathcal{Y}$ כך שכל $c \in C$ $h(x_i) = y_i$

3. הגדירו VC dimension

ממד ה VC (VC dimension) של מחלקת ההיפותזות \mathcal{H} הוא המספר המקסימלי d כך ש $\mathcal{H}|_C \neq \emptyset$



4. השלימו את משפט Sauer-Shelah ~~את משפט Sauer-Shelah~~

אם למחלקה \mathcal{H} יש מימד VC סופי d , אז _____



חלק ג: מודלים הסתברותיים (27 נקודות)

1. בהינתן m הגרלות בת"ל $x_1 \dots x_m$ הנדגמים מהתפלגות אחידה על $\{1, \dots, N\}$ (כאשר N הוא פרמטר של ההתפלגות, מספר טבעי), חשבו את אומד הנראות המקסימלי (MLE) \hat{N} :

2. נתון פריור $p(N)$ על הפרמטר N , כאשר $p(N)$ פונקציה מונוטונית יורדת ממש כפונקציה של N . מהו משעריך ה-MAP?



חלק ד: Stochastic Gradient Descent ו linear regression

1. השלימו את הטיעון הבא בהקשר של Stochastic Gradient Descent:

בהינתן בעיית מינימיזציה רב-מימדית $\min_{w \in \mathbb{R}^d} f(w)$ מעל פונקציה f גזירה, פרוצדורת ה stochastic gradient descent מעדכנת בכל איטרציה t את הפיתרון הנוכחי w_t על ידי צעד מהצורה:
 $w_{t+1} \leftarrow w_t + v_t$, כאשר הווקטור v_t הוא משתנה מקרי המוגרל מהתפלגות שמקיימת:

$$E[v_t] = \underline{\hspace{2cm}}$$

2. בשאלה זו עליכם להשלים קוד שממש Stochastic Gradient Descent עבור Linear Regression. רגרסיה לינארית היא בעיית המינימיזציה (ביחס למקדמים w) של

$$f(w) = \frac{1}{m} \sum_{i=1}^m (\langle x_i, w \rangle - y_i)^2$$

```
import numpy as np

# A function for running stochastic gradient descent
# on a linear regression problem
# x: Sample data of size [m,d], where m is the number
# of samples and d is the dimension. The i'th data point
# equals x[i,:]
# y: labels (real numbers). The i'th label is y[i]
# num_iter: Number of iterations to run
# step_size: Step size of gradient updates
#
```




```
def stochastic_gradient_descent_linear_regression(
    x, y, num_iters, step_size):

    # find the number of samples and the dimension
    m,d = np.size(x)

    # initialize w as zero weight vector
    w = np.zeros(d)

    for iter in range(_____):

        # np.random.randint(N) returns a random
        # number in the range {0,1,...,N-1}
        i = np.random.randint(_____)

        _____

        _____

        _____

        for j in range(_____):

            w[j] = w[j] + _____

    return w
```



3. בשאלה זו עליכם להשלים את קוד שמממש Stochastic Gradient Descent עבור Linear Regression עם רגולריזציה. רגרסיה לינארית עם רגולריזציה היא בעיית המינימיזציה (ביחס למקדמים w) של

$$f(w) = \frac{1}{m} \sum_{i=1}^m (\langle x_i, w \rangle - y_i)^2 + \lambda \|w\|_2^2$$

כאשר λ הוא פרמטר חיובי.

```
import numpy as np

# A function for running stochastic gradient descent
# on a regularized linear regression problem.
# x: Sample data of size [m,d], where m is the number
# of samples and d is the dimension. The i'th data point
# equals x[i,:]
# y: labels (real numbers). The i'th label is y[i]
# num_iter: Number of iterations to run
# step_size: Step size of gradient updates
# lambda: The lambda parameter from the problem
#         definition

def stochastic_gradient_descent_linear_regression(
    x, y, num_iters, step_size, lambda):

    # find the number of samples and the dimension
    m,d = np.size(x)

    # initialize w as zero weight vector
    w = np.zeros(d)

    for iter in range(_____):
```



```
# np.random.randint(N) returns a random
# number in the range {0,1,...,N-1}
i = np.random.randint(_____)

_____

_____

_____

_____

for j in range(_____) :

    w[j] = w[j] + _____

return w
```


4. בסוף המבחן מצורף קוד של תכנית פייתון פשוטה. התוכנית מבצעת את הפעולות הבאות:
- a. מגרילה מטריצת נתונים X של 1000 שורות (דגימות) ו 10 עמודות (מימדים). כל קואורדינטה מוגרלת באופן בת"ל, מהתפלגות אחידה על הקטע $[-0.5, 0.5]$. נסמן ב x_i את הדגימה ה i (השורה ה i במטריצה).
 - b. מגרילה וקטור מקדמים w ממרחב 10 מימדי, כאשר כל קואורדינטה מוגרלת באופן בת"ל מהתפלגות אחידה על $[-0.5, 0.5]$.
 - c. מייצרת סיווגים בינאריים של הדגימות, כאשר הסיווג של דגימה x_i הוא:
$$y_i = \text{sign}(\langle w, x_i \rangle)$$
 - d. מונה על גודל קבוצת אימון m , בין הערכים 10 ל 499 (כולל). עבור כל m :



- i. מפצלת את הדגימות לקבוצת אימון (m הדגימות הראשונות) וקבוצת מבחן ($1000-m$ הדגימות האחרונות)
- ii. פותרת בעיית linear regression (כפי שהוגדר בשאלה 1, כלומר ללא רגולריזציה) ביחס לקבוצת האימון
- iii. מחשבת את שגיאת ה linear regression על קבוצת האימון ועל קבוצת המבחן
- iv. מחשבת את שגיאת ה 0/1 loss על קבוצת האימון ועל קבוצת המבחן. להזכירכם, שגיאה זו על קבוצת נתונים $(x_1, y_1) \dots (x_m, y_m)$ מוגדרת כ
- $$\frac{1}{m} \sum_{i=1}^m \mathbb{I}[y_i \neq \text{sign}(\langle w, x_i \rangle)]$$
- e. משרטטת גרף של שגיאת האימון ושגיאת המבחן ביחס לפונקציית הרגרסיה הלינארית, כפונקציה של m
- f. משרטטת גרף של שגיאת האימון ושגיאת המבחן ביחס לפונקציית ה 0/1 loss, כפונקציית של m
- להלן השירותים שפלטת התכנית. אחד השירותים מתאים ל regression loss והשני ל 0/1 loss:




שירטוט A :





שירטוט B:



סמנו את התשובה הנכונה: שירטוט A מתאים ל

Regression loss ☐

0/1 loss ☐

בכל אחד מהשירטוטים, ישנו עקום אחד הבנוי מסימני '+' (markers), והשני מנקודות '.'.
אחד העקומים מייצג את שגיאת האימון, והשני את שגיאת המבחן.

סמנו את התשובה הנכונה: העקומים המפורטים ב '+' מייצגים את

שגיאת האימון ☐

שגיאת המבחן ☐

לנוחיותכם, אנו מצרפים את הקוד שייצר את השירטוטים, כפי שתואר באופן מילולי לעיל:



```
import numpy as np
import matplotlib.pyplot as plt
from my_ML_library import my_linear_regression_optimizer

# Generate random sample points: 1000 points of 10 dimensions
# Each coordinate uniform in range [-0.5,0.5]
X = np.random.random(size=(1000,10))-0.5

# Generate random weight vector: 10 coordinates uniform in range
# [-0.5,0.5]
w_ = np.random.random(size=(10,1))-0.5

# Generate labels y_i = sign(dot(x[i,:], w_))
y = np.sign(np.matmul(X, w_))

# Prepare vectors for saving error calculations for plot
train_errs_for_plot = []
test_errs_for_plot = []
train_errs_01_for_plot = []
test_errs_01_for_plot = []

# Enumerate over number of training points from 10 to 499
for m in range(10,500):

    # Slice data to train and test
    Xtrain = X[:m,:]
    Xtest = X[m:,:]
    ytrain = y[:m]
    ytest = y[m:]

    # Get optimal (column) coefficient vector
    w = my_linear_regression_optimizer(Xtrain, ytrain)
    w = w.reshape((10,1))

    # Compute training and test error (with respect to linear
```



```
# regression cost)
train_err = np.mean(np.square(np.matmul(Xtrain, w)-ytrain))
test_err = np.mean(np.square(np.matmul(Xtest, w)-ytest))

# compute training and test error (with respect to 0/1 loss)
train_err_01 = \
    np.mean(np.sign(np.matmul(Xtrain, w)*ytrain) - 1.0) * (-0.5)
test_err_01 = \
    np.mean(np.sign(np.matmul(Xtest, w)*ytest) - 1.0) * (-0.5)

# Save error calculations for plot below
train_errs_for_plot.append(train_err)
test_errs_for_plot.append(test_err)
train_errs_01_for_plot.append(train_err_01)
test_errs_01_for_plot.append(test_err_01)

# Plot linear regression train and test errors, as a function
# of training set size m
plt.figure()
plt.xlabel('m')
plt.plot(range(10,500), test_errs_for_plot, 'b')
plt.plot(range(10,500), train_errs_for_plot, 'r')

# Plot 0/1 train and test errors, as a function of training
# set size m
plt.figure()
plt.xlabel('m')
plt.plot(range(10,500), test_errs_01_for_plot, 'b')
plt.plot(range(10,500), train_errs_01_for_plot, 'r')

plt.show()
```