



מבוא למערכות לומדות (236756)

סמינר אביב תשפ"א – 15 ביולי 2021

מרצה: ד"ר ניר רחנfeld

מבחן מסכם מועד א'

הנחיות הבחינה:

- **משך הבחינה:** 3 שעות.
- **חומר עזר:** המבחן בחומר סגור (לא ספרים, מחברות, דפי נוסחאות).
- אין צורך במחשבון.
- מותר לכתוב בעט או בעיפרון, כל עוד הכתב קרייא וברור.
- יש לכתוב את תשובה תיכום **על גבי שאלון זה** בכתב יד קרייא. תשובה בכתב יד שאינו קרייא לא תיבדק.
- במבחן 12 עמודים ממוספרים מה"כ, כולל שער זה שמספרו 1 ושלושה עמודי טיווח בסוף הגילון.
- אין בחירה בין השאלות. יש בסה"כ 104 נקודות והציון המירבי הוא 100.
- נא לכתוב רק את המבוקש ולצער הסברים קצרים **עפ"י** הנחיות.
- **בתום המבחן יש להגיש את שאלון זה בלבד.**
- **בצהוב:** הבחרות שפורסמו בזמן הבחינה.

מבנה הבחינה:

- **חלק א' [72 נק']:** 4 שאלות פתוחות [כל אחת 18 נק']
- **חלק ב' [32 נק']:** 8 שאלות סגורות (אמריקאיות) [כל אחת 4 נק']

בהצלחה!

חלק א' – שאלות פתוחות [72 נק']

שאלה 1 [18 נק']

נתון סט אימון עם תיוגים ביןaries ולומדים עליו מסוג. בסט האימון אין שתי דוגמאות זהות. בעת, בוחרים באקראי 3 דוגמאות אימון שונות וMSCPs אותם (כל אחת עם התיוג שלה) כך שיופיעו פעמיים בסט האימון. לבסוף, מאמנים מסוג חדש על סט האימון המעודכן.

לכל אחד מאלגוריתמי הלמידה הבאים סמן האם גבולות ההחלטה (decision boundaries) של המסוג החדש לאחר השכפול זהים בהכרח לא בהכרח. רק אם סימנתם שהגבולות לא בהכרח זהים, הסבירו בקצרה מדוע. הניחו שאין צעדים סטטיסטיים (אקראים) בירצת האלגוריתמים.

א. 3D המשמש באנתרופופיה ובונה עץ בעומק מרבי 4
גבולות ההחלטה: זהים בהכרח / לא בהכרח זהים

הסבר (אם סימנתם "לא בהכרח"):
ה Entropy נמוך או אם ה + גנאי נכון ווילן (-) פוליאר

הנוף, סטם רקי ייגזג זיגזג כטבוף וכטבוף פוליאר (פער, פער)

ב. NN-k כאשר $k = 1$
גבולות ההחלטה: זהים בהכרח / לא בהכרח זהים

הסבר (אם סימנתם "לא בהכרח"):

ג. NN-k כאשר $k = 3$
גבולות ההחלטה: זהים בהכרח / לא בהכרח זהים

$k = 3$ כאשר $k = 1$

הסבר (אם סימנתם "לא בהכרח"):
הנארז או קחכ (1+) או חטב (1-) או פלט (1+) או פלט (1-)

ווב) כתת גטאות כתטו (+) פלטום (-)

ד. Perceptron בהנחה שהדעתה פריד ליניארית
גבולות ההחלטה: זהים בהכרח / לא בהכרח זהים

הסבר (אם סימנתם "לא בהכרח"):
הנארז או גאנז ערך, כמו כן ה"סומן פ" של (הנארז)

סומן פלטיק ווילטן הטע גראז מהו שורש (גראז וגאנזים)

ה. AdaBoost with decision stumps
גבולות ההחלטה: זהים בהכרח / לא בהכרח זהים

הסבר (אם סימנתם "לא בהכרח"):
הנטטן טטטן גאנז גאנז ערך ווילטן ווילטן

וילטן או גאנז כתטן.

ו. MVM-SVHard בהנחה שהדעתה פריד ליניארית
גבולות ההחלטה: זהים בהכרח / לא בהכרח זהים

הסבר (אם סימנתם "לא בהכרח"):

שאלה 2 [18 נק']

- א. [6 נק'] הוכיחו את תכונת המונוטוניות של VC-dimension
- לכל שתי מחלקות היפותזות, אם $\mathcal{H}_1 \subseteq \mathcal{H}_2$ אז $\text{VCdim}(\mathcal{H}_1) \leq \text{VCdim}(\mathcal{H}_2)$


הוכחה:

$h_1, h_2, \dots, h_k \in \mathcal{H}_1$ מונוטונית יתנו $\mathcal{H}_1 \subseteq \mathcal{H}_2$ וקיים קבוצה $S \subseteq \mathcal{X}$ כך $\text{VCdim}(\mathcal{H}_1) = k$

אם $\mathcal{H}_1 \subseteq \mathcal{H}_2$ וקיים סט $S \subseteq \mathcal{X}$ שמייצר k תתי-קבוצות של S כמפורט לעיל, אז $\text{VCdim}(\mathcal{H}_1) \leq \text{VCdim}(\mathcal{H}_2)$

בתרגול הגדכנו את מחלוקת היפותזות $\mathcal{H}_{\text{aligned}}$ של מבנים מקבילים לצירים בדו-מימד והראינו שמתקיים הבירה: האיזור שבתו המלבן מסווג כחיובי והאיזור החיצוני כשלילי.

כעת נגדיר את מחלוקת היפותזות $\mathcal{H}_{\text{centered}}$ של מבנים מקבילים לצירים בדו-מימד **שומרץם** בדיק בראשית הצירים.



$$\text{VCdim}(\mathcal{H}_{\text{centered}}) = \boxed{2}$$

ב. [6 נק'] מהו מימד ה-VC של המחלוקת החדשה? מלאו.

ג. [6 נק'] הוכחו את תשובתכם לסעיף הקודם.

הוכחה: נקח וקטור \vec{v} , הנ' :

$$S = \{(0,2), (1,0)\}$$

השער מילוי הטענה הולא: $\text{VCdim}(H) \geq 2$

נראה שקיים זוג וקטורים $y_1 = y_2 = +1$, דהיינו $y_1 = y_2 = -1$.

נראה שקיים זוג וקטורים $y_1 = +1, y_2 = -1$.

נראה שקיים זוג וקטורים $y_1 = -1, y_2 = +1$.

נראה שקיים זוג וקטורים $y_1 = +1, y_2 = +1$.

נראה שקיים זוג וקטורים $y_1 = -1, y_2 = -1$.

נראה שקיים זוג וקטורים $y_1 = +1, y_2 = 0$.

נראה שקיים זוג וקטורים $y_1 = -1, y_2 = 0$.

נראה שקיים זוג וקטורים $y_1 = 0, y_2 = +1$.

נראה שקיים זוג וקטורים $y_1 = 0, y_2 = -1$.

נראה שקיים זוג וקטורים $y_1 = 0, y_2 = 0$.

$\text{VCdim}(H) \leq 3$: מכיוון שקיים זוג וקטורים y_1, y_2 אשר מתקיימת $y_1(x) = y_2(x)$ ו- $y_1(x) \neq y_2(x)$.

$\text{VCdim}(H) = 2$ $\text{VCdim}(H) \geq 2$ $\text{VCdim}(H) \geq 2$

שאלה 3 [ק' 18]

נתון סט אימון עם דוגמאות חד-ממדיות \mathbb{R} ותיוגים רציפים $y_1, \dots, y_m \in \mathbb{R}$, $x_1, \dots, x_m \in \mathbb{R}$.

$$\hat{w} = \operatorname{argmin}_{w \in \mathbb{R}} (\sum_{i=1}^m (wx_i - y_i)^2 + R(w))$$

פתרונות בעיית גרסה ליניארית עם רגולרייזציה (עם $\lambda = 1$):

בפתרון שהתקבל, המשקל שמתאים למאפיין היחיד מקיים $0 \neq \hat{w}$.

בעת, משכפלים את המאפיין היחיד כך שכל דוגמה מעודכנת היא וקטור \mathbb{R}^2

$$\hat{\mathbf{u}} = \operatorname{argmin}_{\mathbf{u} \in \mathbb{R}^2} \left(\underbrace{\sum_{i=1}^m (\mathbf{u}^\top \mathbf{x}'_i - y_i)^2}_{\triangleq \mathcal{L}'(\mathbf{u})} + R(\mathbf{u}) \right).$$

לבסוף, פותרים את הבעיה המעודכנת:

הבהרה: הפונקציה R מקבלת סקלר או וקטור ומחזיר אותה הנורמה שלו (בסעיפים א'-ב': L_2 ביריבוע, בסעיף ג': L_1).

. $\mathbf{u} = \begin{bmatrix} \widehat{\mathbf{v}} \\ 0 \end{bmatrix}$ כאשר $(\mathbf{v}_j)^2$ נציג כפיתרון לבעה המעודכנת את הווקטור \mathbf{u} .

הוכחו שהו פיתרון לא אופטימלי על ידי הצעת פיתרון אחר $\mathbf{z} \in \mathbb{R}^2$ המקיים $\mathcal{L}'(\mathbf{z}) + R(\mathbf{z}) < \mathcal{L}'(\mathbf{u}) + R(\mathbf{u})$

$$L'(u) = \sum (\hat{\omega} x_i - y_i)^2$$

$$\mathbf{z} = \left[\frac{1}{2} \hat{\mathbf{w}}, \frac{1}{2} \hat{\mathbf{w}} \right]$$

$$\left. \begin{array}{l} R(u) = \|w\|^2 \\ R(\Sigma) = \frac{1}{2} \|w\|^2 \end{array} \right\} R(\Sigma) < R(u)$$

ב. [6 נק'] כאשר $R = \|\mathbf{v}\|_2^2 \triangleq \sum_i (v_i)^2$ סמננו את הטעינה הנכונה בהכרח והסבירו בקצרה.

a. אחד המשקלים שווה לאפס (משמעותו:

$$\text{c)} \quad R(w) = |w| \\ R(2) = \frac{1}{4}|w| + \frac{1}{w}|w| = \frac{1}{2}|w|$$

q.b) שני המשקלים שונים מפאס (משמעות: $\hat{u}_1 \neq 0 \wedge \hat{u}_2 \neq 0$)

c. שני המקרים b, a אפשריים

הסבירו בקצרה: **מי** **נמלט** **רכז** **מי** **אנו** **נמלט** **רכז**

John will begin to feel better once he has

ג. נק' [6] כאשר $\|v\|_1 = \sum_j |v_j|$, סמננו את הטעינה הנכונה בהכרח והסבירו בקצרה.

a. אחד המשקלים שווה לאפס (משמעותו:

b. שני המשקלים שונים מפאס (משמעות: $\hat{u}_1 \neq 0 \wedge \hat{u}_2 \neq 0$)

c. שני המקרים b, a אפשריים

הסבירו בקצרה:

שאלה 4 [18 נק']

הזכירו בבעיות האופטימיזציה של ה-SVM במקרה ללא הומוגני:

Hard SVM

$$\begin{aligned} \operatorname{argmin}_{\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}} & \|\mathbf{w}\|_2^2 \\ \text{s.t. } & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad \forall i \in [m] \end{aligned}$$

Soft SVM

$$\operatorname{argmin}_{\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}} \left(\frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b)\} + \lambda \|\mathbf{w}\|_2^2 \right)$$

א. [4 נק'] כתבו וקטור שמהווה subgradient לפי \mathbf{w} לפונקציית loss של ה-SVM.

תשובה סופית (לרשומכם עמודי טיווח בסוף השאלה):

$$\nabla_{\mathbf{w}} \left(\frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b)\} + \lambda \|\mathbf{w}\|_2^2 \right) = \begin{cases} 2\lambda \mathbf{w} ; & y_i \mathbf{w}^\top \mathbf{x}_i + b \geq 1 \\ 2\lambda \mathbf{w} - \frac{1}{m} \sum_{j \neq i} y_j \mathbf{x}_j ; & y_i \mathbf{w}^\top \mathbf{x}_i + b < 1 \end{cases}$$

ב. [6 נק'] לכל אחת מהטענות הבאות, סמן אם היא (בהכרח) **נכונה** / **שגויה** / **לא ניתן לדעת** והסבירו בקצרה.
א. עבור סט אימון פריד ליניארית, Hard-SVM מגיע ל-**train accuracy** מזוהה עם **test accuracy**.

הטענה: **נכונה** / **שגויה** / **לא ניתן לדעת**.

הסבר: (1) כריך פונקציית כויה מ-100%

ב. עבור סט אימון פריד ליניארתי, Soft-SVM מגיע ל-**test accuracy** מזוהה עם Hard-SVM.

הטענה: **נכונה** / **שגויה** / **לא ניתן לדעת**.

הסבר: וכן גורם אמצעים של ה-hard ו-hard לא יגאלים יחסית מsoft
וכן גורם אמצעים של hard ו-hard לא יגאלים יחסית מsoft

- ג. [8 נק'] נתון דатаה פריך ליניארית עם תיוגים ביןaries. פתרים עלי SVM-Hard ומקבלים כפתרון $\mathbf{w}^d \in \mathbb{R}^d$ ו- $b_1 \in \mathbb{R}$. ידוע שהפתרון שהתקבל הוא הפיתרון היחיד לבעה.

עכשו פתרים בעיה SVM-Hard margin=2. משמע, עם אילוצים מעודכנים $2 \geq (\mathbf{w}^T \mathbf{x}_i + b)$.

את הפיתרון החדש נסמן ב- $\mathbf{w}_2 \in \mathbb{R}^d$ ו- $b_2 \in \mathbb{R}$.

smaller norm

בכל אחד מהסעיפים הבאים סמנו את התשובה הנכונה ומלאו את החסר (היכן שנדרש).

- א. יתכן שלבעה המעודכנת אין פתרון, למשל כאשר המרחק בין המחלקות לא מספיק גדול למרות שהדטה פריך ליניארית.

הטענה: נכונה / שגויה.

- ב. אם קיים פתרון לבעה המעודכנת אז הפרדייקציות הבינהריות זהות. משמע, $(\mathbf{x}) \cdot (\mathbf{w}_1, b_1) = (\mathbf{x}) \cdot (\mathbf{w}_2, b_2)$.

הטענה: נכונה / שגויה.

$$y_i(\mathbf{w}_1^T \mathbf{x}_i + b_1) \geq 1/2$$


$$y_i((2\mathbf{w}_1^T \mathbf{x}_i + 2b_1) \geq 2$$

- כ. אם קיים פתרון לבעה המעודכנת אז קיים סקלר α עבורו $\mathbf{w}_2 = \alpha \mathbf{w}_1$.

הטענה: נכונה והסקלר שווה ל- 2 / שגויה.

- ד. אם קיים פתרון לבעה המעודכנת אז קיים סקלר β עבורו $b_2 = \beta b_1$.

הטענה: נכונה והסקלר שווה ל- 2 / שגויה.



חלק ב' – שאלות אמריקאיות [32 נק']

בשאלות הבאות סמננו את התשובות המתאימות (לפי ההוראות). בחלק זה אין צורך לכתוב הסברים.

א. [4 נק'] ~~מזכורת: $\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$, $\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$~~

~~נתון זאהה עם תאגים ביןarios (P או N, לפחות דוגמה אחת מכל תיוג).~~

~~סמננו את כל הטענות השויות.~~

א. ערך-h-(AUC) Area under the curve האופטימלי של עקומת ROC הוא 1

b. מתקיים $\text{Precision} + \text{Recall} = 1$

c. תמיד קיים מודל שמשיג $\text{Recall} = 1$

d. ניתן ליצור Confusion matrices רק בעיות עם תיוגים ביןarios (שתי מחלקות)

e. בדאייה מאבחן ($\Pr[y = P]$), מידי ה- h - Precision וה- Recall נהנים שקיים למדד ה- Accuracy

ב. [4 נק'] נרצה להרחיב את מודל ה-NN-k לבעיות **רגסיה** ($x_i \in \mathbb{R}^d$, $y_i \in \mathbb{R}$).

נגידור את (x)NN להיות קבוצת האנדקסים של a השכנים הקרובים ביותר ל- x .

סמננו את שתי פונקציות החיזוי (של u בהינתן x) המתאימות ביותר לעביה.

~~$h(x) = \frac{1}{k} \sum_{i \in \text{NN}(x)} x_i$~~

b $h(x) = \frac{1}{k} \sum_{i \in \text{NN}(x)} y_i$

~~$h(x) = \sum_{i \in \text{NN}(x)} (\|x - x_i\|_2 y_i)$~~

*זיהוי לא חלה טעות
לעין לא מושג, מושג* $h(x) = \sum_{i \in \text{NN}(x)} \left(\frac{\exp\{-\|x - x_i\|_2\}}{\sum_{j \in \text{NN}(x)} \exp\{-\|x - x_j\|_2\}} y_i \right)$ d. [5 נק']

~~$h(x) = \sum_{i \in \text{NN}(x)} (\max\{0, \|x - x_i\|_2^2\} y_i)$~~

ג. [4 נק'] נתונים סט אימון וסט מבחן הנדגמים מהתפלגות כלשהי D ומחלקה היפותזית כלשהי H .


בוחרים היפותזה מתרון המחלקה ע"י ERM.

עתה מוסיפים לשט האימון מספר דוגמאות חדשות (הנדגמות מ- D), ולומדים היפותזה חדשה ע"י MRM על H .

כל סוג שגיאה **סמננו** את האפשרות המתאימה בהכרח.

a. שגיאת האימון: תעלה / תרד / לא תשתחנה / לא ניתן לדעת

b. שגיאת המבחן: תעלה / תרד / לא תשתחנה / לא ניתן לדעת



ד. [4 נק'] מה התפקיד של פונקציית h-sigmoid במסוג regression logistic? סמננו את התשובה הנכונה.

~~a~~ להכניס non-linearity ולהפוך את ה- margin להסתברות


b. להפוך את ה- margin למספר שמלמד

c. לעשות רגרסיה פולינומיאלית בין $x \in \mathbb{R}^d$ ל- $y \in \mathbb{R}$

d. להוסיף גאורייציה למסוג שנלמד

e. למקסם את האנטרופיה

ה. [נק'] נתון דатаה שנדגים מהתפלגות אחידה על ספירה (sphere) תלת-ממדית סביב ראשית הצירים. מפעילים PCA כדי להוריד ממד מ-3 ל-2. הקיפו את האות שמתאימה לתרשים של הדטה לאחר הורדת הממד.



ו. [נק'] נתונה בעית `.multiclass`.

אימנו מסוג All vs. One (שיטת א') ומסוג `multinomial logistic regression` (שיטת ב').

לאחר האימון, נוספה לבעה מחלוקת חדשה עם דוגמאות חדשות.

על מנת להתמודד עם המחלוקת החדשה (סמננו את הטענה הנכונה ב'וטר):

בשיטה א' אנחנו צריכים לאמן רק מסוג אחד נוספת ואין שינוי במסוגים שכבר אומנו

ב. בשיטה ב' אנחנו צריכים לאמן רק מסוג אחד נוספת ואין שינוי במסוגים שכבר אומנו

שתי הטענות $a+b$ נכונות

כל הטענות הקודמות שגויות

ז. [נק'] נסתכל על רשת Multi-Layer Perceptron לרגרסיה שלומדת פונקציה $h: \mathbb{R}^d \rightarrow \mathbb{R}$.

כפונקציית אקטיבציה נשתמש בפונקציית הזהות $z = z(\sigma)$. לסיום, נשתמש ב-loss ריבועי (MSE) ללא רגולריזציה.

סמננו את הטענה הנכונה.

כמחלקה מודלים, ה-capacity של זהה של מודלים ליניארים (linear regression) ?

השכבה האחורה ברשות צריכה להיות שכבת Softmax

לביעית האופטימיזציה יש מינימום גלובלי יחיד

d. כל הטענות הקודמות שגויות

ח. [נק'] נתונות דוגמאות $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^d$, $y_1, \dots, y_m \in \{-1, +1\}$ מתוויות באופן ביןארי, משמע $\{-1, +1\}$.

רוצים למדוד הורדת ממד ליניארית (בעזרת מטריצה \mathbf{W}) ל- k ממדים כאשר $d \gg k$.

רוצים לשאלח הטללה, דוגמאות מתוויות זהים תהיה קרובות אחת לשניה ורחוקות מהדוגמאות של התיאוג השני.


סמננו את בעית האופטימיזציה (היחידה) שמתאימה לפיתרון הבעה.

$$\underset{\mathbf{W} \in \mathbb{R}^{k \times d}}{\operatorname{argmin}} \left(\sum_{i,j} \|\mathbf{W}\mathbf{x}_i - \mathbf{W}\mathbf{x}_j\|_2^2 \right) .a$$


$$\underset{\mathbf{W} \in \mathbb{R}^{k \times d}}{\operatorname{argmin}} \left(\sum_{i,j} \|\mathbf{W}\mathbf{x}_i - \mathbf{W}\mathbf{x}_j\|_2^2 + \sum_{i,j:y_i \neq y_j} \|y_i - y_j\|_2^2 \right) .b$$

$$\underset{\mathbf{W} \in \mathbb{R}^{k \times d}}{\operatorname{argmin}} \left(\sum_{i,j:y_i=y_j} \|\mathbf{W}\mathbf{x}_i - \mathbf{W}\mathbf{x}_j\|_2^2 + \sum_{i,j:y_i \neq y_j} \max \{0, 1 - \|\mathbf{W}\mathbf{x}_i - \mathbf{W}\mathbf{x}_j\|_2^2\} \right) .c$$

$$\underset{\mathbf{W} \in \mathbb{R}^{k \times d}}{\operatorname{argmin}} \left(\sum_{i,j:y_i \neq y_j} \ln \left(1 + \|\mathbf{W}\mathbf{x}_i - \mathbf{W}\mathbf{x}_j\|_2^2 \right) + \sum_{i,j} (W_{i,j})^2 \right) .d$$




מסגרת נוספת לשימושכם (יש לציין אם מדובר בטיווח או בהמשך לתשובה אחרת):




A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.

מסגרת נוספת לשימושכם (יש לציין אם מדובר בטיווח או בהמשך לתשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.

מסגרת נוספת לשימושכם (יש לציין אם מדובר בטיווח או בהמשך לתשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.