



מבוא למערכות לומדות (236756)

סמסטר אביב תשפ"ב – 12 ביולי 2022

מרצה: ד"ר ניר רחנfeld

## מבחן מסכם מועד א'

הנחיות הבחינה:

- **משך הבחינה:** 3 שעות.
- **חומר עזר:** המבחן בחומר סגור (לא ספרים, מחברות, דפי נוסחאות).
- מותר להשתמש במחשבון.
- יש לכתוב בעט  **בלבד**.
- יש לכתוב את התשובות **על גבי שאלון זה**.
- מותר לענות בעברית או באנגלית.
- **קריאות:**
  - תשובה בכתב יד לא קרי – **לא תיבדק**.
  - בשאלות רב-ברירה – הקפידו להקיף את התשובות **בבירור**. סימונים לא ברורים יביאו לפסילת התשובה.
  - לא יתקבלו ערעורים בנושא.
- במבחן 16 עמדים ממושפרים סה"כ, כולל עמוד שער זה שמספרו 1 ושלושה עמודי טיווח בסוף הגילון.
- נא לכתב רק את המבוקש ולצרכ' הסברים קצרים **עפ"י** ההנחיות.
- **בתום המבחן יש להגיש את שאלון זה בלבד.**

מבנה הבחינה:

- **חלק א' [26 נק']:** 4 שאלות פתוחות.
- **חלק ב' [24 נק']:** 4 שאלות סגורות (אמריקאיות) [כל אחת 6 נק'].

**בהצלחה!**

## חלק א' – שאלות פתוחות [76 נק']

שאלה 1: [20] Feature selection and Classification models

נתון סט אימון עם  $3 \geq d$  מאפיינים (features) ועם תיוגים בינאריים, משמע  $\{-1, 1\}$ .

בסט האימון אין שתי דוגמאות זהות.

נתון שהקורסיה בין שני מאפיינים מסויימים  $A, B$ ,  $A$  בסט האימון היא בדיקת 1.

משמע, לכל דוגמה  $i$  מתקיים  $b < ax_i[A] + b \in \mathbb{R}$ .

לומדים שני מסוגים:

- בשלב הראשון: לומדים מסוג על סט האימון המקורי ומחשבים עליו את דיקוק האימון.
- בשלב השני:

  - מסירים את המאפיין  $B$  ומתקבלים סט אימון מעודכן (שבו  $1 - d$  פיצרים).
  - מאמנים מסוג חדש על סט האימון המעודכן, ומחשבים עליו את דיקוק האימון המעודכן.

עבור כל אלגוריתם במידה, סמנו האם דיקוק האימון של המסוג חדש על סט האימון המעודכן זהה בהכרח לזה של המסוג  המקורי על סט האימון המקורי.

**הסבירו בקצרה את תשובותיכם (4-2 משפטים בכל סעיף).**

הנicho שאין צעדים סטטיסטיים (אקראיים) בRICT האלגוריתמים ואין שגיאות נומריות (בפרט, בעיות קמורות מתכוננות לפתרון האנליטי שלهن במדוק).

א. NN k עם  $1 = k$  (דוגמה לא נחשבת שכנה של עצמה).

הסבירו: נניח כי ב- B קוץ לא ההוקף בסביבה של הנקודה, כלומר לא כל נק

הנקודות הסמוכות לה נמצאות בolygon (וואר) יגד

ב. Hard-SVM ליניארי לא הומוגני בהנחה שהדאטה המקורי פריד.

הסביר: (ב) ה-הנורמל (ה-פונקציונלי)

הנתקן ב-100%. ו-73% מ-70%

ג. SVM-Soft לינארי לא הומוגני עם  $1 = \lambda$  בהנחה שהדעתה המקורי פריד. דיקט האימון זהה בהכרח? כן / לא

הסביר: החלטה יכלה להיות "מחייבת" רק במקרה אחד.

18. *Levi-Civita symbol*

Wavelength (nm) Intensity (a.u.)

דיק אימון זהה בהכרח? כן / לא

ד. D3 המשמש באנתרופופיה ובונה עץ בעומק מירבי 4.

הסביר: הנתקלאן / הנתקלאן הנתקלאן

A  $\rightarrow$  B (בנוי) משלים, B  $\rightarrow$  C משלים  $\text{curl } \rho$  מ- B

162, 163, 164

## שאלה 2: Kernel SVM [18 נק']

תזכורת: פונקציה מהויה קרNEL חוקי אם ניתן לכתוב אותה בטור  $\phi(u)\phi(v) \rightarrow \sum_{i=1}^n \phi_i(u)\phi_i(v)$ . משמע, מתקיים: עבור מיפוי כלשהו  $\mathcal{X} \rightarrow \mathbb{R}^n$ .

נתונות שתי פונקציות קרNEL חוקיות  $\mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ :  $K_1, K_2: (\mathcal{X} \times \mathcal{X}) \rightarrow \mathbb{R}^n$  ומיופיעים המתאימים להן  $\phi, \psi: \mathcal{X} \rightarrow \mathbb{R}^n$ . משמע, מתקיים:

$$K_1(u, v) = \langle \phi(u), \phi(v) \rangle, \quad K_2(u, v) = \langle \psi(u), \psi(v) \rangle$$

הוכיחו שהפונקציות הבאות מהוות קרNEL חוקיים (כפי שמוסבר בתזכורת לעיל).

בכל סעיף, הגדרו בבירור פונקציית מיפוי  $\mathcal{X} \rightarrow \mathbb{R}^{n'}$  המתאימה והראו שמתקיים  $\langle \phi'(u), \phi'(v) \rangle = K'(u, v)$  כנדרש.

א. [5 נק'] הפונקציה  $K'(u, v) = (K_1(u, v))^2$

הוכחה:

$$\begin{aligned} K'(u, v) &= (K_1(u, v))^2 = \langle \varphi(u), \varphi(v) \rangle^2 = \\ &= \left( \sum_{i=1}^n \varphi_i(u) \varphi_i(v) \right)^2 = \sum_{i=1}^n \varphi_i(u) \varphi_i(v) \sum_{j=1}^n \varphi_j(u) \varphi_j(v) = \\ &= \sum_{i=1}^n \sum_{j=1}^n (\varphi_i(u) \varphi_j(u)) (\varphi_i(v) \varphi_j(v)) \Rightarrow \\ &\Rightarrow \varphi': \mathcal{X} \rightarrow \mathbb{R}^{n^2} \end{aligned}$$

לינן גראטורה או גראטורה יפה יפה וריאנט או גראטורה היפר-טולווער

ב. [5 נק'] הפונקציה  $K'(u, v) = K_1(u, v) + 3 \cdot K_2(u, v) + 1$

הוכחה:

$$\begin{aligned} K'(u, v) &= \sum_{i=1}^n (\varphi_i(u) \varphi_i(v) + 3 \sum_{i=1}^n \psi_i(u) \psi_i(v) + 1) = \\ &= \left( \sum_{i=1}^n (\varphi_i(u) \varphi_i(v) + 3 \psi_i(u) \psi_i(v)) + 1 \right) \Rightarrow \varphi': \mathcal{X} \rightarrow \mathbb{R}^{2n+1} \end{aligned}$$

$\varphi': \mathcal{X} \rightarrow \mathbb{R}^{2n+1}$

$(uv)^2 + uv + 1$ ג. [8 נק'] אילו מהפעולות הבאות אמורות להפחית ב-SVM overfitting?

סמן את כל התשובות המתאימות (השאלה אינה עוסקת במקרי קצה אלא במקרה הסביר)  $\binom{uv}{?}$

x. עבור מפונקציית הkernel  $p$   $K(u, v) = (u^T v + 1)^p$ , כאשר  $\mathbb{N}_{\geq 2} \in p$ .

x. להקטין את השונות  $\sigma^2$  של kernel RBF (משמעותו בטור  $\rightarrow -\infty \rightarrow 0 \rightarrow \infty$ )  $\binom{\text{NN}}{?}$

x. לפטור (במדיוק) את הבעיה primal במקום לפטור (במדיוק) את הבעיה dual.

x. להגדיל את מקדם הרגוליזציה  $\lambda$  (בהתחמה: להקטין את  $C$ ).  $\binom{\text{לגדיל עלייה על } \lambda}{?}$

o. להגדיל את סט האימון (באופן d. i. מאותה התפלגות של הדטה המקורי).

x. להגדיל את סט המבחן (באופן d. i. מאותה התפלגות של הדטה המקורי).

## שאלה 3: VC-dimension [16 נק']

נגידר את מחלקת הhipothesizes של מסווגים ליניארים הומוגניים ב- $d$  ממדים:

$$\mathcal{X} = \mathbb{R}^d, \quad \mathcal{H}_{\text{lin}}^d = \{x \mapsto \text{sign}(w^T x) : w \in \mathbb{R}^d\}$$

כדי למנוע טוויות, נקבע שלאורך כל השאלה  $0 = \text{sign}(0)$  (ואהחרת הפונקציה מחזירה  $\pm 1$  בהתאם לסימן).

א. [7 נק'] הוכחו שמתקיים  $\text{VCdim}(\mathcal{H}_{\text{lin}}^d) \geq d$ .

הוכחה:  
זהו

$$e_1 = [1, 0, \dots, 0], e_2 = [0, 1, 0, \dots, 0], \dots, e_d = [0, \dots, 0, 1]$$

לפי הטענה  $y_1, \dots, y_d \in \mathcal{X}, \mathcal{H}^d$ , יהי  $\omega \in \mathcal{C}$  (לפי הטענה  $\mathcal{C}$  מוגדר כsubset של  $\mathcal{H}^d$ )

$$\omega = (y_1, \dots, y_d)$$

ב:

$$\omega^T x_i = (y_1, \dots, y_d)^T \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 0 \end{pmatrix} = y_i$$

$$h(x) = \text{Sign}(\omega^T x) = \text{Sign}(y_i) = y_i \quad \text{as wanted}$$

$H$  shatters  $C$ ,  $|C| = d = \text{VCdim}(\mathcal{H}_{\text{lin}}^d) \geq d$

ב. [9 נק'] הוכחו שמדד ה-VC הוא בדיק  $d$  על ידי כך שתוכicho שמתקיים  $d+1$  במתן: כל אוסף  $x_1, \dots, x_d, x_{d+1}$  של  $d+1$  וקטורים כלשהם ב- $\mathbb{R}^d$  הינו תלוי ליניארית, ובהכרה אחד הווקטורים באוסף (בה"כ) מקיימים  $x_{d+1} = \sum_{i=1}^d z_i x_i$  עבור אוסף סקלרים  $\mathbb{R} z_1, \dots, z_d \in \mathbb{R}$  שלפחות אחד מהם שונה מ-0.

הוכחה (לרשotecם דפי טיוטה בסוף הגילוון):

$$\text{הוכחה: } \forall x_1, \dots, x_{d+1} \in \mathbb{R}^d \quad \exists z_1, \dots, z_d \in \mathbb{R} \quad \text{כך } x_{d+1} = \sum_{i=1}^d z_i x_i$$

הוכחה: נניח  $x_{d+1} = \sum_{i=1}^d z_i x_i$  ונתנו  $y_1, \dots, y_{d+1} \in \{-1, 1\}$ .  
 $\exists h: \mathbb{R}^d \rightarrow \{-1, 1\}$  כך  $h(x_i) = y_i \quad \forall i = 1, \dots, d+1$ .

$$\forall y_1, \dots, y_{d+1} \in \{-1, 1\} \quad \exists h: \mathbb{R}^d \rightarrow \{-1, 1\} \quad \text{כך } h(x_i) = y_i \quad \forall i = 1, \dots, d+1$$

$$y_i = \begin{cases} \text{Sign}(z_i) & i \leq d \\ -1 & i = d+1 \end{cases} \quad \text{לפחות אחת ה-} y_i \text{ היא לא-} 0$$

$$\forall i: \text{Sign}(\omega^\top x_i) = y_i \quad \text{כדי ש-} \omega \in \mathbb{R}^d \quad \text{היה}$$

$$-1 = \text{Sign}(\omega^\top x_{d+1}) = \text{Sign}\left(\omega^\top \sum_{i=1}^d z_i x_i\right) = \text{Sign}\left(\sum_{i=1}^d z_i (\omega^\top x_i)\right) \geq 0 \Rightarrow \text{Sign}() = 1$$

$$\forall i: \text{Sign}(\omega^\top x_i) = y_i \quad \text{כדי ש-} \omega \in \mathbb{R}^d \quad \text{היה}$$

Initialize  $D^{(1)} = \left(\frac{1}{m}, \dots, \frac{1}{m}\right)$

For  $t=1, \dots, T$ :

$$h_t = \mathcal{A}(S, D^{(t)})$$

$$\epsilon_t = \sum_i D_i^{(t)} \cdot \mathbf{1}_{h_t(x_i) \neq y_i}$$

$$\alpha_t = \frac{1}{2} \log \left( \frac{1}{\epsilon_t} - 1 \right)$$

$$D_i^{(t+1)} = \frac{1}{z_t} D_i^{(t)} \exp(-\alpha_t y_i h_t(x_i))$$

$$h_s(x) = \text{sign}\left(\sum_{t=1}^T \alpha_t h_t(x)\right)$$

## שאלה 22] Bagging and Boosting :4

משמאל מופיע אלגוריתם AdaBoost.

א. [5 נק'] שימוש לב סכום איטרציה האלגוריתם מעדכן את התפלגות באוון

באשר  $Z_t \triangleq \sum_{j=1}^m D_j^{(t)} \exp(-\alpha_t y_j h_t(x_j))$

הוכחו שמתקיים ( $D_i^{(t+1)} = c \cdot \exp(-y_i \sum_{k=1}^t \alpha_k h_k(x_i))$  עבור קבוע כלשהו  $c > 0$  שתלויב- $t$ ).

$$\hat{D}_i^{(2)} = \frac{1}{Z_1} \underbrace{D_i^{(1)}}_{c} e^{-\omega_j y_j h_{\alpha}(x_i)}$$

הוכחה (לרשומכם דפי טיווה בסוף הגילוון): **הוכחה:**

$$\hat{y}_i^{(1)} = C \cdot e^{-y_i \sum_{k=1}^{l-1} \alpha_k h_k(x_i)} = C \cdot e^{-\alpha_1 h_1(x_i) y_i} \cdot \dots \cdot e^{-\alpha_{l-1} h_{l-1}(x_i) y_i}$$

$$D_i^{(t+1)} = \frac{1}{Z_1} D_i^{(t)} \cdot e^{-\alpha_i y_i h_i(x_i)} = C \cdot e^{-y_i \alpha_i h_i(x_i)} \cdot \dots \cdot e^{-y_i \alpha_i h_i(x_i)} =$$

$$C = \frac{C}{Z_1} - \frac{\sum_{k=1}^n \alpha_k h_{k2}(x_i)}{e^{C' + \sum_{k=1}^n \alpha_k h_{k1}(x_i)}}$$

בסעיף הבא נוכיח שהבחירה של האלגוריתם ב- $\alpha_t = \frac{1}{2} \log\left(\frac{1}{\epsilon_t} - 1\right)$  היא אופטימלית.

$$h_s^{(t)} = \sum_{k=1}^t \alpha_k h_k(x_i)$$

תזכורת: הגדרנו בתרגול את ההיפותזה  $\text{-unthresholded}$  ה"חזקת" באיטרציה  $t$  בטור: והראינו שקיימים קבוע  $C$  כך שערך ה- $\text{loss}$  של היפותזה הוא:

$$\mathcal{L}_{\exp}\left(h_s^{(t)}\right) \triangleq \frac{1}{m} \sum_{i=1}^m \exp\left\{-y_i \sum_{k=1}^t \alpha_k h_k(x_i)\right\} = \underbrace{C}_{>0} \cdot \left(e^{-\alpha_t} + (e^{\alpha_t} - e^{-\alpha_t}) \sum_i D_i^{(t)} \mathbf{1}_{h_t(x_i) \neq y_i}\right)$$

כאשר  $C$  אינו תלוי בבחירה של המקבץ  $\alpha_t$  שנבחר בזמן  $t$ .

ב. [5 נק'] הוכיחו שבבינtron  $h_t$  ו- $\{\alpha_t\}_{i \in [m]}$ , הבחירה  $\alpha_t = \frac{1}{2} \log\left(\frac{1}{\epsilon_t} - 1\right)$  מינימiert את  $\mathcal{L}_{\exp}(h_s^{(t)})$

הערה: שימוש לב-ש- $\epsilon_t$  והוא קבוע בהינתן  $h_t$  ו- $\{\alpha_i\}_{i \in [m]}$ :

$$\nabla_{\alpha_t} \mathcal{L}_{\exp} = C \left( -\bar{e}^{-\alpha_t} + \left( \bar{e}^{\alpha_t} + \bar{e}^{-\alpha_t} \right) \mathbb{E}_t \right) = 0 \quad / : \text{הוכחה:}$$

$$\mathbb{E}_t \bar{e}^{-\alpha_t} - \bar{e}^{-\alpha_t} + \mathbb{E}_t \bar{e}^{\alpha_t} = 0 \quad / :$$

$$\bar{e}^{\alpha_t} (\mathbb{E}_t - 1) + \mathbb{E}_t \bar{e}^{\alpha_t} = 0 \quad / \cdot \bar{e}^{\alpha_t}$$

$$\mathbb{E}_t - 1 + \mathbb{E}_t \bar{e}^{2\alpha_t} = 0$$

$$\bar{e}^{2\alpha_t} = \frac{1 - \mathbb{E}_t}{\mathbb{E}_t} \Rightarrow 2\alpha_t = \ln\left(\frac{1}{\mathbb{E}_t} - 1\right) \Rightarrow$$

$$\Rightarrow \alpha_t = \frac{1}{2} \ln\left(\frac{1}{\mathbb{E}_t} - 1\right)$$

למראת כוכב נורמי יPLIC (נורמי נורמי)

181  $\alpha_t = \frac{1}{2} \ln\left(\frac{1}{\mathbb{E}_t} - 1\right)$

הסעיף הבא לא קשור לאלגוריתם AdaBoost אלא לשיטת Ensemble שמשקלת היפותזות באופן כללי.

ג. [12 נק'] נתון סט אימון  $\{x_i, y_i\}_{i=1}^m$  עם סיוגים בינהירים  $\{-1, +1\}$ .

צווות של 50 מומחים ומומחיות הגדר ידנית 50 היפותזות בינהירות  $\{ -1, +1 \}$ .

המטרה שלנו היא למשקל אותן, משמע, ליצור היפותזה  $h_\alpha(x) = \text{sign}(\sum_{k=1}^{50} \alpha_k h_k(x))$

כדי למנוע טעויות, נקבע שלאורך כל השאלה  $0 = \text{sign}(0)$  (ואהחרת הפונקציה מחזירה  $1 \pm$  בהתאם לסימן).

נתון: קיימים משקלים  $\alpha_1, \dots, \alpha_{50} \in \mathbb{R}$  כך שהשגיאה האמפירית (שגיאת האימון) היא אפס.

בעת, נרצה ללמד אוסף משקלים  $\alpha_1, \dots, \alpha_{50} \in \mathbb{R}$ .

(ii) נסחו בעית אופטימיזציה מתאימה קמורה (ביחס למשקלים הנלמדים  $\alpha_1, \dots, \alpha_{50}$ ) כך שהפתרונות שלה מażער את השגיאה האמפירית.

$$h(x) = [h_1(x), \dots, h_{50}(x)]^\top \in \mathbb{R}^{50}$$

$$\text{תשובה (לרשוטכם טויטה בסוף הגילון):}$$

$$\underset{\alpha \in \mathbb{R}^{50}}{\operatorname{argmin}} \sum_{i=1}^m \max\{0, 1 - y_i \alpha^\top h(x_i)\}$$

(ii) נמכו בקצרה מדוע הבעיה שהגדרתם קמורה (מומלץ להשתמש בטענות מההרצאה ומהתרגול).

תשובה (לרשוטכם טויטה בסוף הגילון):

$$\text{ב-1} \leq y_i \leq 1, \quad \leftarrow \text{טנו}, \quad \leftarrow \text{האנו} \geq \text{האנו}$$

$$\text{וכו } \leftarrow \text{האנו} \geq \text{האנו} \geq \text{האנו}$$

(iii) יהיו אוסף המשקלים  $\alpha = \alpha_0, \dots, \alpha_m$  פיתרון (אופטימלי) של בעיה הקמורה שהגדתם לעיל.  
הוכחו שהשגיאה האמפירית של פיתרון זה היא מינימלית.

$$\forall i: \text{Sign}(\alpha^T h(x_i)) = y_i \in \{\pm 1\} \quad \therefore \alpha^* = [\alpha_0, \dots, \alpha_m] \quad (1)$$

$$(=R) \quad \text{נוב} \quad y_i \alpha^{*T} h(x_i) > 0 \quad (2)$$

$$\forall i: y_i \beta \alpha^{*T} (h(x_i)) = 2 > 1 \quad \therefore \beta = \frac{2}{R} \quad (3)$$

כפונקציית ה- $\ell_1$  מינימלית

Surrogate loss function (כיצד)

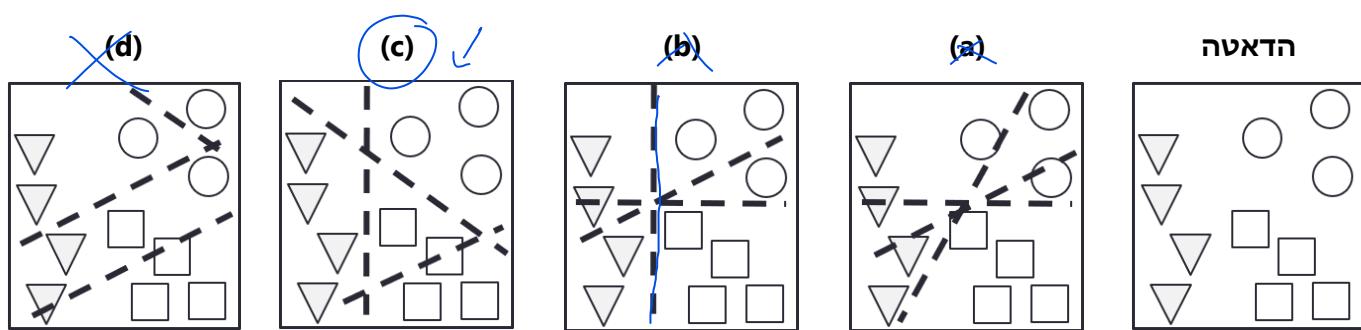
פונקציית האמצע (mean)

פונקציית האמצע (mean)

## חלק ב' – שאלות אמריקאיות [24 נק']

בשאלות הבאות סמננו את התשובות המתאימות (לפי ההוראות). בחלק זה אין צורך לכתוב הסברים.

- א. [6 נק'] נתון דאטה דו-ממדי עם שלושה תיוגים אפשריים – משולש, מעגל וריבוע. מפעלים All-*vs*-All (OVA) עם פרספטורון בטור מסווג בסיס. לכל בעיה ביןארית מרכיבים את הפרספטורון מספיק איטרציות כך שאם הבעיה פרידה ליניארית – הפרספטורון יתכנס (חישבו מה קורה אחרת). בכל תרשימים מצוירים שלושה גבולות החלטה שאמורים לתאר את הגבולות שהתקבלו ע"י מסווגי הבסיס (הבינאריים). **הקיפו** את האות שמתאימה לתרשים היחיד שמתאר גבולות החלטה שיכולים להתקבל ע"י השיטה שתוארה לעיל.



- ב. [6 נק'] נתון דאטה  $d$ -ממדי  $\{(x_i, y_i)\}_{i=1}^m$  עם סיוגים ביןאריים ( $\pm 1$ ).).

סמננו את כל הטענות הנכונות **בהכרח** ביחס **לשיטות להורדת ממד** לממד נמוך כלשהו.

הבהרה: זו שאלת חשיבה ולא שאלת טריוויה.

- א. הדאטה המקורי פריד ליניארית  $\Leftarrow$  הדאטה פריד ליניארית לאחר הורדת ממד ליניארית עם PCA.
- ב. הדאטה המקורי פריד ליניארית  $\Leftarrow$  בהסתברות גבוהה, הדאטה פריד ליניארית לאחר הורדת ממד ליניארית עם Random Projections.
- ג. הדאטה המקורי פריד ליניארית  $\Leftarrow$  הדאטה פריד ליניארית לאחר הורדת ממד עם Kernel-PCA (עם קרנל לא ליניארי).
- ד. הדאטה פריד ליניארית לאחר הורדת ממד ליניארית עם PCA  $\Leftarrow$  הדאטה המקורי פריד ליניארית.
- ה. PCA היא שיטה Supervised בעוד ש Random Projections היא שיטה Unsupervised.

ג. [6 נק'] נתונה בעית וגרסיה לינארית (עבור  $\lambda \geq 0$ ,  $p \in \{0.5, 1, 2\}$ )

$$\operatorname{argmin}_{\mathbf{w}} \left( \frac{1}{m} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_p^p \right) = \operatorname{argmin}_{\mathbf{w}} \left( \frac{1}{m} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_p^p \right)$$

סמןו את כל הטענות הנכונות.

**הערה:** בכל הסעיפים, שואלים על קמירות ביחס ל-*w*.

מזכורת:  $\|w\|_p^p \triangleq \sum_{k=1}^d |w_k|^p$

~~א.~~ כאשר  $0 = \lambda$ : ההסיאן הוא  $X^T X - \frac{2}{m}$  שהיא מטריצה PSD אבל לא בהכרח PD, ולכן הבועיה לא בהכרח קמורה.

b) כאשר  $0 > \lambda$  וגם  $2 = d$ : הבעיה קמורה בהכרח.

c. כאשר  $0 < \lambda$  וגם  $1 = d$ : הבעיה קמורה בהכרח.

כאשר  $0 < \lambda$  וגם  $0.5 = d$ : הבעה קמורה בהכרח.

א. כאשר  $0 < \lambda$  וגם  $1 = d$ : הבעייה אינה גזירה ביחס ל- $w$  ולכן ניתן להפעיל שיטות גרדינט (או סאב-גרדינט).

ד. [6 נק'] רוצים לאמנו רשת נירונית בתוצאות Autoencoder.

$\hat{x}_i \in \mathbb{R}^d$  נסמן את אוסף כל הפרמטרים של הרשת בטור  $\theta$ . לכל דוגמה  $i \in x$  נסמן את הפלט של הרשת בטור

בهرצתה ראיינו שנייתן לאמן את הרשות ע"י פיתרון הבעה הבא:  $\arg\min_{\Theta} \left( \lambda \|\Theta\|_2^2 + \frac{1}{m} \sum_{i=1}^m \|x_i - \hat{x}_i\|_2^2 \right)$

אילו מבין הביעות הבאות עשויות גם כן להתאים לאימון רשת Autoencoder (עבור  $0 > \lambda$ )?

סמן את כל התשובות המתאימות.

$$\operatorname{argmin}_{\Theta} \left( \lambda \|\Theta\|_2^2 + \frac{1}{m} \sum_{i=1}^m \|x_i + \hat{x}_i\|_2^2 \right) .$$

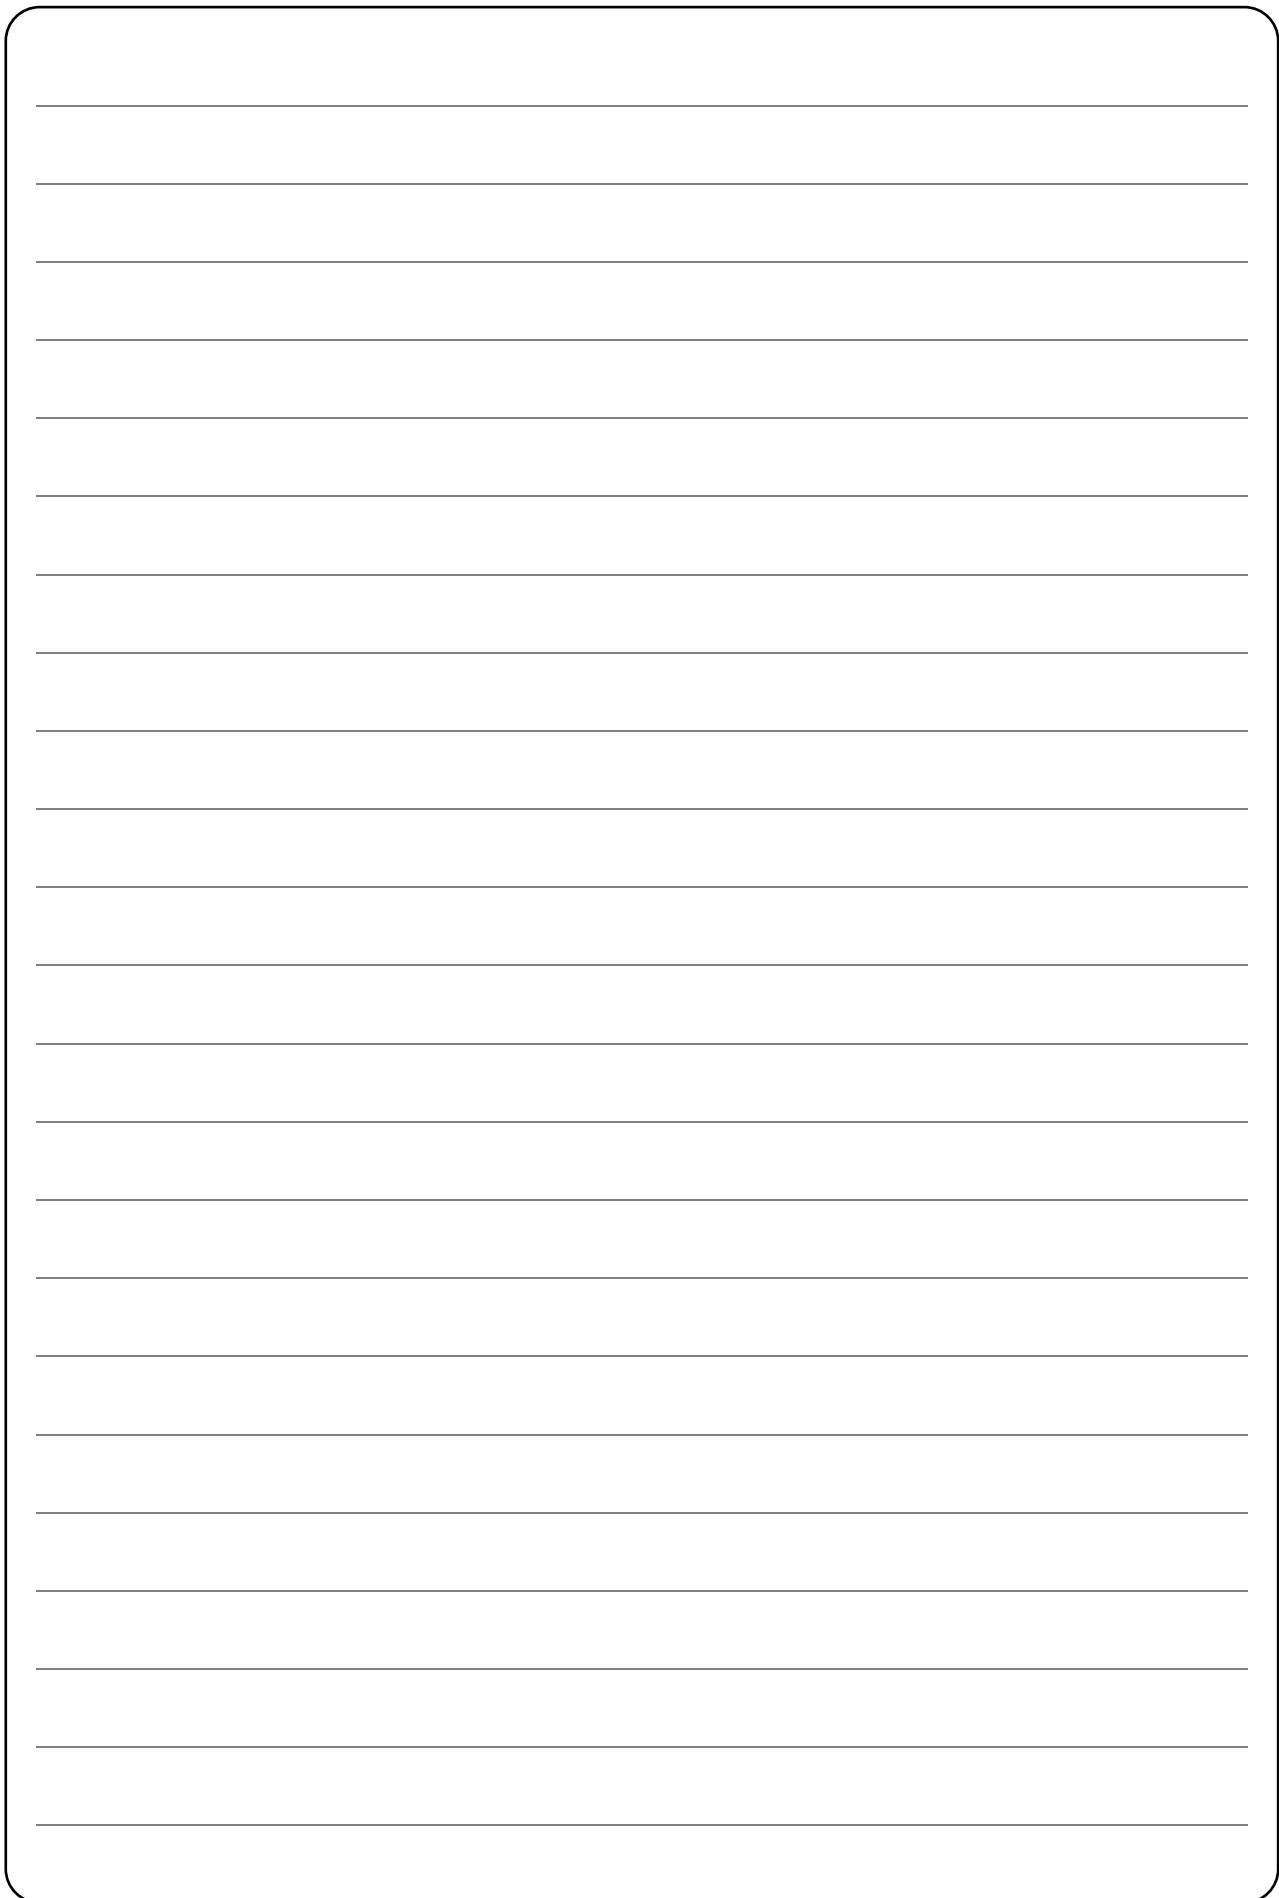
$$\text{argmin}_{\Theta} \left( \lambda \|\Theta\|_2^2 + \frac{1}{m} \sum_{i=1}^m \exp\{\|x_i - \hat{x}_i\|_2^2\} \right) .$$

$$\operatorname{argmin}_{\Theta} \left( \lambda \|\Theta\|_2^2 - \frac{1}{m} \sum_{i=1}^m \|x_i\|_2^2 + \frac{1}{m} \sum_{i=1}^m \|x_i - \hat{x}_i\|_2^2 \right) . c$$

$$\operatorname{argmin}_{\Theta} \left( \lambda \|\Theta\|_2^2 + \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - \text{sign}(x_i^\top \hat{x}_i)\} \right) .$$

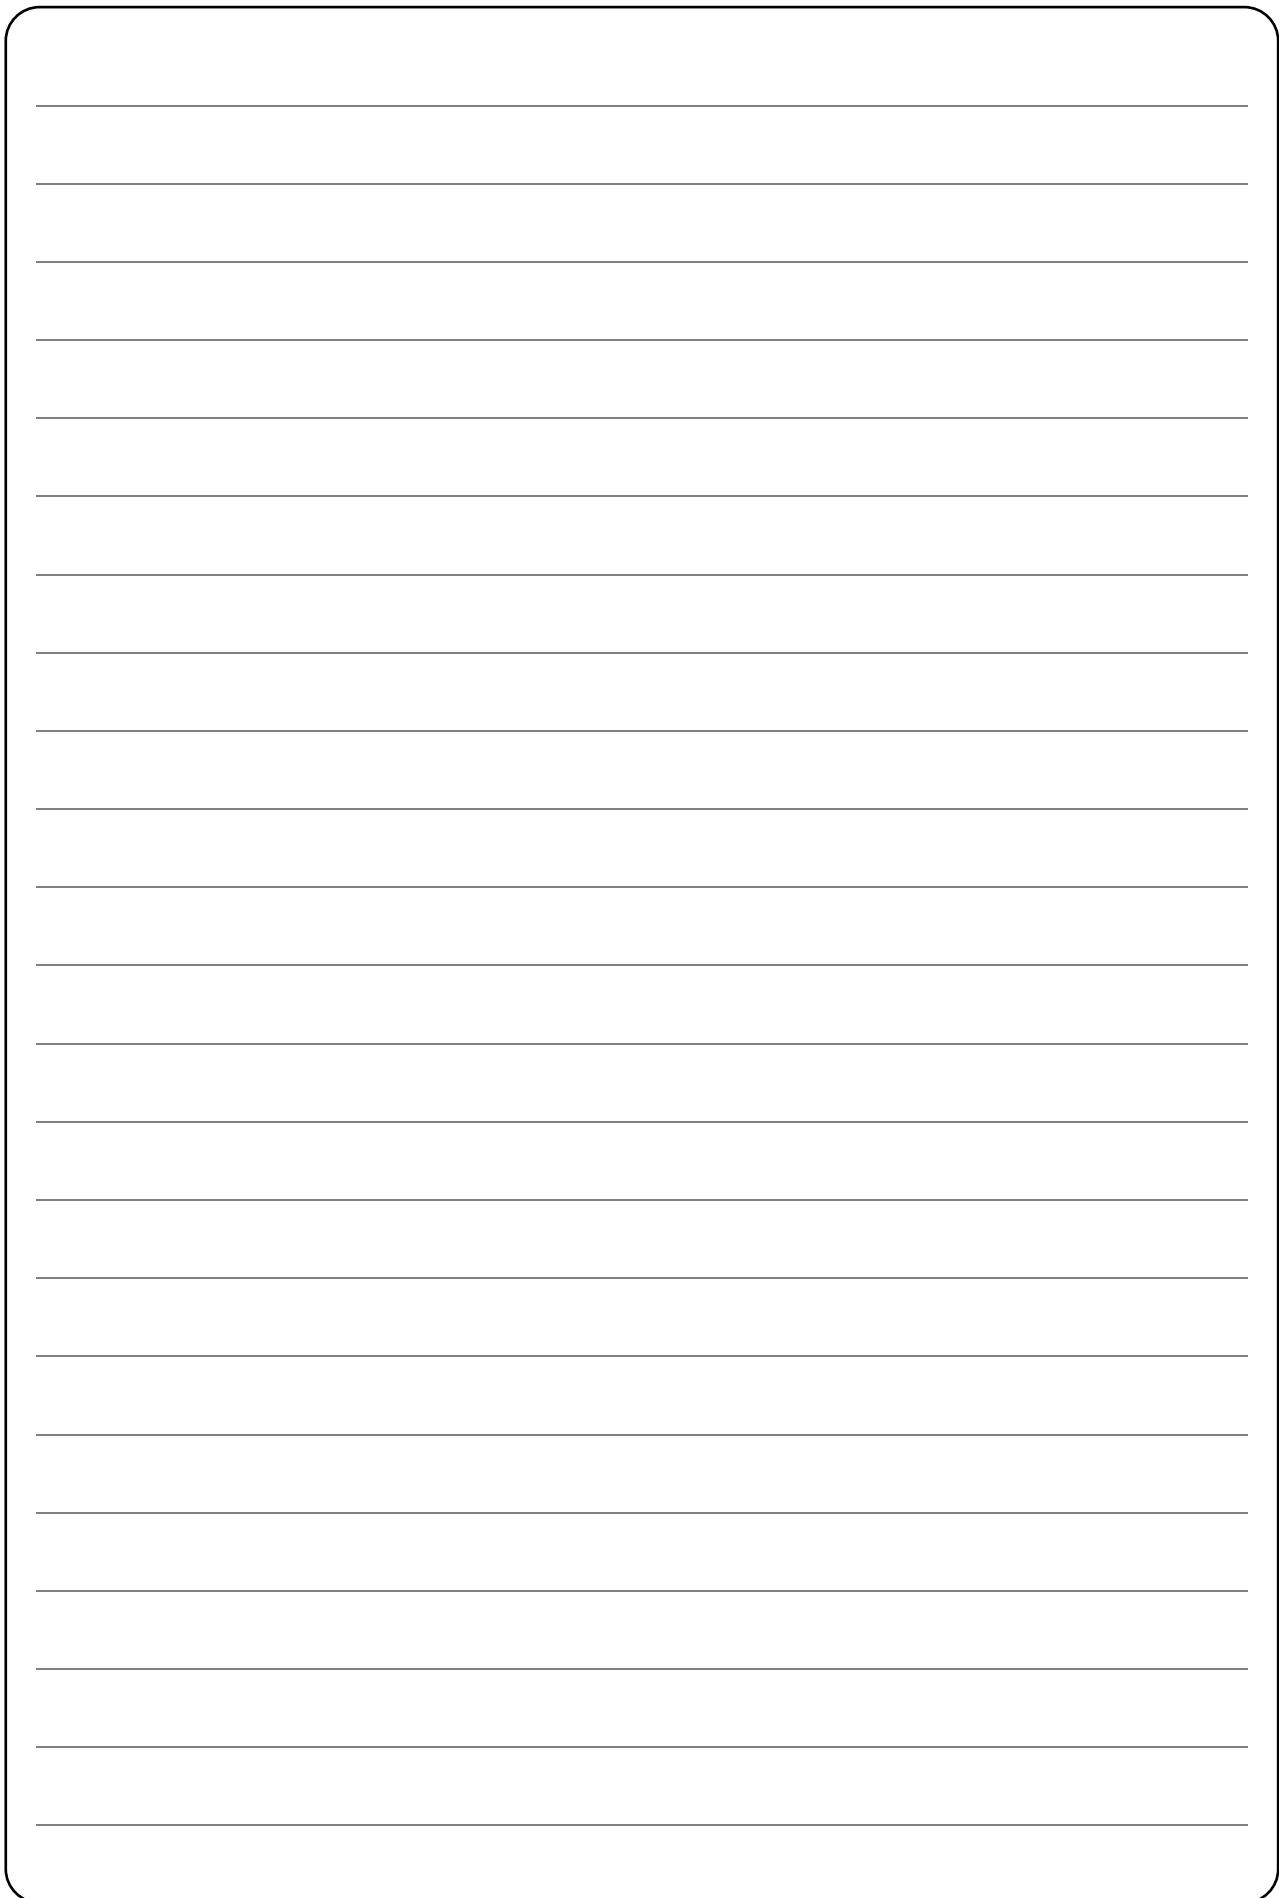
$$\operatorname{argmin}_{\Theta} \left( -\lambda \|\Theta\|_2^2 + \frac{1}{m} \sum_{i=1}^m \frac{x_i^\top \hat{x}_i}{\|x_i\|_2 \|\hat{x}_i\|_2} \right) .$$

מסגרת נוספת (יש לציין אם מדובר בטيوטה או בהמשך לשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.

מסגרת נוספת (יש לציין אם מדובר בטيوטה או בהמשך לשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.

מסגרת נוספת (יש לציין אם מדובר בטיוטה או בהמשך לשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.