



מבוא למערכות לומדות (236756)

סמסטר אביב תשפ"ב – 12 ביולי 2022

מרצה: ד"ר ניר רחנfeld

## מבחן מסכם מועד א'

הנחיות הבחינה:

- **משך הבחינה:** 3 שעות.
- **חומר עוז:** המבחן בחומר סגור (לא ספרים, מחברות, דפי נוסחאות).
- מותר להשתמש במחשבון.
- יש לכתוב בעט **בלבד**.
- יש לכתב את התשובות **על גבי שאלון זה**.
- מותר לענות בעברית או באנגלית.
- **קריאות:**
  - תשובה בכתב יד לא קרי – **לא תיבדק**.
  - בשאלות רב-ברירה – הקפידו להקיף את התשובות **בבירור**. סימונים לא ברורים יביאו לפסילת התשובה.
  - לא יתקבלו ערעורים בנושא.
- במבחן 16 עמדים ממושפרים סה"כ, כולל עמוד שער זה שמספרו 1 ושלושה עמודי טיווח בסוף הגילון.
- נא לכתב רק את המבוקש ולצרכ' הסברים קצרים **עפ"י** ההנחיות.
- **בתום המבחן יש להגיש את שאלון זה בלבד.**

מבנה הבחינה:

- **חלק א' [26 נק']:** 4 שאלות פתוחות.
- **חלק ב' [24 נק']:** 4 שאלות סגורות (אמריקאיות) [כל אחת 6 נק'].

**בהצלחה!**

## חלק א' – שאלות פתוחות [76 נק']

**שאלה 1:** 20] Feature selection and Classification models

נתון סט אימון עם  $3 \geq d$  מאפיינים (features) ועם תיוגים בינאריים, משמע  $\{-1,1\}$ .  
 $x_i \in \mathbb{R}^d, y_i \in \{-1,1\}$

בסט האימון אין שתי דוגמאות זהות.

נתון שהקורסיה בין שני מאפיינים מסויימים  $B, A$ , בסט האימון היא בדיקת  $A$ .

משמע, לכל דוגמה  $i$  מתקיים  $b < a < x_i[B]$ .

לומדים שני מסוגים:

- שלב הראשון: לומדים מסוג על סט האימון המקורי ומחשבים עליו את דיקוק האימון.
- שלב השני:

  - מסירים את המאפיין  $B$  ומתקבלים סט אימון מעודכן (שבו  $1 - d$  פיצרים).
  - מאמנים מסוג חדש על סט האימון המעודכן, ומחשבים עליו את דיקוק האימון המעודכן.

עבור כל אלגוריתם במידה, סמנו האם דיקוק האימון של המסוג חדש על סט האימון המעודכן זהה בהכרח לזה של המסוג  המקורי על סט האימון המקורי.

**הסבירו בקצרה את תשובותיכם (4-2 משפטים בכל סעיף).**

הנicho שאין צעדים סטטיסטיים (אקראיים) בRICTת האלגוריתמים ואין שגיאות נומריות (בפרט, בעיות קמורות מתכוננות לפתרון האנליטי שלhn במדדיק).

א. NNN עם  $1 = k$  (דוגמה לא נחשבת שכנה של עצמה).

הסבר:

---



---



---

דיק האימון זהה בהכרח? כן / לא

ב. SVM-Hard לינארי לא הומוגני בהנחה שהדעתה המקורי פריד.

הסבר:

ג. SVM-Soft לינארי לא הומוגני עם  $\gamma = \lambda$  בהנחה שהדעתה המקורי פריד. דיק האימון זהה בהכרח? כן / לא

הסבר:

דיק האימון זהה בהכרח? כן / לא

ד. 3D המשמש באנתרופולוגיה ומבנה עצ בעומק מירבי 4.

הסבר:

## שאלה 2: Kernel SVM [18 נק']

תזכורת: פונקציה מהויה קרNEL חוקי אם ניתן לכתוב אותה בטור  $\phi(u)\phi(v) = \sum_{i=1}^n \phi_i(u)\phi_i(v)$ .

נתונות שתי פונקציות קרNEL חוקיות  $\mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ :  $K_1, K_2: (\mathcal{X} \times \mathcal{X}) \rightarrow \mathbb{R}^n$ .

$$K_1(u, v) = \langle \phi(u), \phi(v) \rangle, \quad K_2(u, v) = \langle \psi(u), \psi(v) \rangle$$

הוכיחו שהfonקציות הבאות מהוות קרNEL חוקיים (כפי שמוסבר בתזכורת לעיל).

בכל סעיף, הגדרו בבירור פונקציית מייפוי  $\mathcal{X} \rightarrow \mathbb{R}^{n'}$  המתאימה והראו שמדוברים בKernel.

א. [5 נק'] הפונקציה  $K'(u, v) = (K_1(u, v))^2$

הוכחה:

$$K'(u, v) = (K_1(u, v))^2 = \sum_{i=1}^n \varphi_i(u)\varphi_i(v) \sum_{j=1}^n \varphi_j(u)\varphi_j(v) = \sum_{i=1}^n \sum_{j=1}^n (\varphi_i(u)\varphi_i(v))(\varphi_j(u)\varphi_j(v)) \Rightarrow$$

$$\varphi'(u) = (\varphi_1(u)\varphi_1(u), \varphi_2(u)\varphi_2(u), \dots, \varphi_n(u)\varphi_n(u))$$

$$\varphi': \mathcal{X} \rightarrow \mathbb{R}^{n^2}$$

ב. [5 נק'] הפונקציה  $K'(u, v) = K_1(u, v) + 3 \cdot K_2(u, v) + 1$

הוכחה:

$$K'(u, v) = \sum_{i=1}^n \varphi_i(u)\varphi_i(v) + 3 \sum_{i=1}^n \psi_i(u)\psi_i(v) + 1 =$$

$$= \sum_{i=1}^n [\varphi_i(u)\varphi_i(v) + 3\psi_i(u)\psi_i(v)] + 1 =$$

$$\varphi(u) = [\varphi(u), \sqrt{3}\psi(u), 1]$$

ג. [8 נק'] אילו מהפעולות הבאות אמורות להפחית ב-SVM overfitting ?  
סמן את כל התשובות המתאימות (השאלה אינה עוסקת במקרים קצה אלא במקרה הסביר).

ג. עבור מפונקציית הkernel  $p$   $K(\mathbf{u}, \mathbf{v}) = (\mathbf{u}^\top \mathbf{v} + 1)^p$ , כאשר  $\mathbb{N}_{\geq 2} \in p$ .

ג. להקטין את השונות  $\sigma^2$  של Kernel RBF (משמעותו  $\sigma^2 = \frac{1}{2\sigma^2} \|\mathbf{u} - \mathbf{v}\|_2^2$ ) על ידי  $\sigma^2 \rightarrow 0$ .

ג. לפטור (במדויק) את הבעיה primal במקום לפטור (במדויק) את הבעיה dual.

$$\varphi(u) = (u^2, \sqrt{2}u, 1)$$

$$(uv)^2 = u^2v^2 \quad \varphi(u) = (u^2)$$

$$\varphi(u) = u^p$$

ד. להגדיל את מקדם הרגוליזציה  $\lambda$  (בהתאם להקטין את  $C$ ).

ד. להגדיל את סט האימון (באופן d. i. מאותה התפלגות של הדאטה המקורי).

ד. להגדיל את סט המבחן (באופן d. i. מאותה התפלגות של הדאטה המקורי).

### שאלה 3: VC-dimension [7 נק']

נגיד את מחלקת הhipothesizes של מסוגים ליניאריים הומוגניים ב- $d$  ממדים:

$$\mathcal{X} = \mathbb{R}^d, \quad \mathcal{H}_{\text{lin}}^d = \{x \mapsto \text{sign}(w^T x) : w \in \mathbb{R}^d\}$$

כדי למנוע טוויות, נקבע שלאורך כל השאלה  $0 = \text{sign}(0)$  (ואהחרת הפונקציה מחזירה  $\pm 1$  בהתאם לסימן).

א. [7 נק'] הוכחו שמתקיים  $d \geq \text{VCdim}(\mathcal{H}_{\text{lin}}^d)$ .

הוכחה:  
זה  
הוכחה?

$$\forall_{\{x_i\}}: \quad X_i = [0, \dots, 0, 1, 0, \dots, 0]$$

$\forall_{\{x_i\}}: w_i = y_i \quad \text{means } y_i \in \{\pm 1\} \quad \text{וגם } \forall i \text{ we have } w_i = y_i$

$$\forall_{\{x_i\}} y_i w^T x_i = y_i (y_1 y_2 \dots y_d) / \|w\|_2 = y_i \quad (\text{because } w = (w_1, w_2, \dots, w_d))$$

$y_i^2 > 0$

$$\sum_{i=1}^d (-y_i w^T x_i) = 0 \quad \text{because}$$

לפנינו יש  $0$ , אחד או כמה נקודות יוניקות בפונקציית ה- $\text{sign}$

$\text{VCdim}(\mathcal{H}_{\text{lin}}^d) \geq d \iff \text{we can find } d \text{ points such that any } d \text{ of them can pass through the line}$

ב. [9 נק'] הוכחו שמדד ה-VC הוא בדיק  $d$  על ידי כך שתוכicho שמתקיים  $d+1$  במתן: כל אוסף  $x_1, \dots, x_d, x_{d+1}$  של  $d+1$  וקטורים כלשהם ב- $\mathbb{R}^d$  הינו תלוי ליניארית, ובהכרה אחד הוקטורים באוסף (בה"כ) מקיימים  $x_{d+1} = \sum_{i=1}^d z_i x_i$  עבור אוסף סקלרים  $\mathbb{R} z_1, \dots, z_d \in \mathbb{R}$  שלפחות אחד מהם שונה מ-0.

הוכחה (לרשotecם דפי טויטה בסוף הגילון):

$$\left( \text{1} \quad \text{לעפיה גראט 8) כבאי 2/11/2022, ור פלאח כבאי 2/11/2022} \right)$$

הוכחה בדעתנו  $x_i \in \mathbb{R}^d$ ,  $X_{d+1} = \sum_{i=1}^d z_i x_i$ , נס כראה  $\mathbb{R}^d$ , גרי הרוב נגנ'ן,  $x_1, \dots, x_{d+1}$

$$y_i = \begin{cases} \text{Sign}(z_i) & i \leq d \wedge z_i \neq 0 \\ 1 & i \leq d \wedge z_i = 0 \\ -1 & i = d+1 \end{cases}$$

נשא כי קיימת  $w \in \mathbb{R}^d$  כך ש  $w^\top x_i = y_i$

$$\text{Sign}(w^\top x_{d+1}) = \text{Sign}\left(w^\top \sum_{i=1}^d z_i x_i\right) = \text{Sign}\left(\sum_{i=1}^d z_i \underbrace{w^\top x_i}_{\geq 0}\right) = 1 \neq -1 = y_{d+1}$$

כיוון שהעוג יתבצע גם במקרה  $w^\top x_i = y_i$  ו- $w$  נס

כיוון שזאת עוג כ- $y_{d+1}$  לא יתבצע גם במקרה  $w^\top x_i = y_i$  ו- $w$  נס

$\text{VCdim}(\mathcal{H}_{\text{lin}}^d) \leq d+1$  מכאן עוג כ- $y_{d+1}$  לא יתבצע גם במקרה  $w^\top x_i = y_i$  ו- $w$  נס

Initialize  $D^{(1)} = \left(\frac{1}{m}, \dots, \frac{1}{m}\right)$

For  $t=1, \dots, T$ :

$$h_t = \mathcal{A}(S, D^{(t)})$$

$$\epsilon_t = \sum_i D_i^{(t)} \cdot \mathbf{1}_{h_t(x_i) \neq y_i}$$

$$\alpha_t = \frac{1}{2} \log\left(\frac{1}{\epsilon_t} - 1\right)$$

$$D_i^{(t+1)} = \frac{1}{Z_t} D_i^{(t)} \exp(-\alpha_t y_i h_t(x_i))$$

$$h_s(x) = \text{sign}\left(\sum_{t=1}^T \alpha_t h_t(x)\right)$$

## שאלה 4: [22 נק'] Bagging and Boosting

משמאל מופיע אלגוריתם AdaBoost.

א. [5 נק'] שימו לב שבכל איטרציה האלגוריתם מעדכן את ההתפלגות באופן  $(x_i)$  והוא גורם נירמול.

$$\text{כasher } Z_t \triangleq \sum_{j=1}^m D_j^{(t)} \exp(-\alpha_t y_j h_t(x_j))$$

הוכחו שמתקיים  $D_i^{(t+1)} = c \cdot \exp(-y_i \sum_{k=1}^t \alpha_k h_k(x_i))$  ( $c$  שתלו ב- $t$ -ה).

$$\begin{aligned} D_i^{(t+1)} &= \frac{1}{Z_t} D_i^{(t)} e^{-y_i h_t(x_i)} = \frac{1}{Z_t Z_{t-1}} D_i^{(t-1)} e^{-y_i \alpha_t h_t(x_i)} = \dots \\ &= \frac{1}{\prod_{i=1}^t Z_i} e^{-y_i \sum_{k=1}^t \alpha_k h_k(x_i)} \end{aligned}$$

בסעיף הבא נוכיח שהבחירה של האלגוריתם ב- $\alpha_t = \frac{1}{2} \log\left(\frac{1}{\epsilon_t} - 1\right)$  היא אופטימלית.

$$h_s^{(t)} = \sum_{k=1}^t \alpha_k h_k(x_i)$$

תזכורת: הגדרנו בתרגול את הhipotzaה-unthresholded ה"חזקת" באיטרציה  $t$  בטור: והראינו שקיים קבוע חיובי  $C$  כך שערך loss. של היפותזה הוא:

$$\mathcal{L}_{\exp}\left(h_s^{(t)}\right) \triangleq \frac{1}{m} \sum_{i=1}^m \exp\{-y_i \sum_{k=1}^t \alpha_k h_k(x_i)\} = \underbrace{C}_{>0} \cdot \left(e^{-\alpha_t} + (e^{\alpha_t} - e^{-\alpha_t}) \sum_i D_i^{(t)} \mathbf{1}_{h_t(x_i) \neq y_i}\right)$$

כאשר  $C$  אינו תלוי בבחירה של המקבץ  $\alpha_t$  שנבחר בזמן  $t$ .

ב. [5 נק'] הוכחו שהבינהן  $h_t$  ו- $\{\alpha_t\}_{i \in [m]}$ , הבחירה ב- $\alpha_t = \frac{1}{2} \log\left(\frac{1}{\epsilon_t} - 1\right)$  מזערת את  $\mathcal{L}_{\exp}(h_s^{(t)})$

הערה: שימוש לב ש- $\epsilon_t \triangleq \sum_i D_i^{(t)} \cdot \mathbf{1}_{h_t(x_i) \neq y_i}$  והוא קבוע בהינתן  $h_t$  ו-

$$\frac{\partial \mathcal{L}_{\exp}(h_s^{(t)})}{\partial \alpha_t} = \cancel{\int \left(-e^{-\alpha_t} + \epsilon_t e^{\alpha_t} + \epsilon_t e^{-\alpha_t}\right)} = 0 \quad / \cdot e^{\alpha_t}$$

הוכחה:

$$-1 + \epsilon_t e^{2\alpha_t} + \epsilon_t = 0 \Rightarrow e^{2\alpha_t} = \frac{1-\epsilon_t}{\epsilon_t} \Rightarrow 2\alpha_t = \log\left(\frac{1-\epsilon_t}{\epsilon_t}\right) \Rightarrow$$

$$\Rightarrow \alpha_t = \frac{1}{2} \log\left(\frac{1}{\epsilon_t} - 1\right)$$

הסעיף הבא לא קשור לאלגוריתם AdaBoost אלא לשיטת Ensemble שמשקלת היפותזות באופן כללי.

ג. [12 נק'] נתון סט אימון  $\{(x_i, y_i)\}_{i=1}^m$  עם סיוגים בינהירים  $\{-1, +1\}$ .

צווות של 50 מומחים ומומחיות הגדר ידנית 50 היפותזות בינהירות  $\{ -1, +1 \}$ .

המטרה שלנו היא למשקל אותן, משמע, ליצור היפותזה  $h_\alpha(x) = \text{sign}(\sum_{k=1}^{50} \alpha_k h_k(x))$

כדי למנוע טיעויות, נקבע שלאורך כל השאלה  $0 = \text{sign}(0)$  (ואהחרת הפונקציה מחזירה  $1 \pm$  בהתאם לסימן).

נתון: קיימים משקלים  $\alpha_1, \dots, \alpha_{50} \in \mathbb{R}$  כך שהשgiaה האמפירית (שגיאת האימון) היא אפס.

כעת, נרצה ללמד אוסף משקלים  $\alpha_1, \dots, \alpha_{50} \in \mathbb{R}$ .

(ii) נסחו בעית אופטימיזציה מתאימה **קמורה** (ביחס למשקלים הנלמדים  $\alpha_1, \dots, \alpha_{50}$ ) כך שהפתרונות שלה מażע את השgiaה האמפירית.

תשובה (לרשוטכם טויטה בסוף הגילון):

$$h(x) = [h_1(x), \dots, h_{50}(x)]^\top \in \{-1\}^{50} \quad \alpha = [\alpha_1, \dots, \alpha_{50}] \in \mathbb{R}^{50}$$

~~$$\underset{\alpha \in \mathbb{R}^{50}}{\operatorname{argmin}} \sum_{i=1}^m \max\left\{0, 1 - y_i \sum_{k=1}^{50} \alpha_k h_k(x_i)\right\}$$~~

$$\boxed{\underset{\alpha \in \mathbb{R}^{50}}{\operatorname{argmin}} \sum_{i=1}^m \max\left\{0, 1 - y_i \alpha^\top h(x_i)\right\}}$$

(ii) נזכיר בקצרה מדוע הבעיה שהגדתם קמורה (מומלץ להשתמש בטענות מההרצאה ומהתרגול).

תשובה (לרשוטכם טויטה בסוף הגילון):

כיון שהפונקציה  $\max(0, \cdot)$  היא פונקציית מינימום אובייקטיבית,

וכיוון שהיא אובייקטיבית,

(iii) יהיו אוסף המשקלים  $\alpha \in \mathbb{R}^{50}, \dots, \alpha_1$  פיתרון (אופטימלי) של בעיה הקמורה שהגדתם לעיל.  
הוכחו שהשגיאה האמפירית של פיתרון זה היא מינימלית.

הוכחה:

$$y_i \alpha^* h(x_i) > 0 \quad \text{ולכן} \quad \text{Sign}(\alpha^* h(x_i)) = y_i \quad \text{ז"כ } \alpha^* \text{ סביר}$$

נניחו כי סיבוב כוונון  $\beta$  אינו סביר כפלו כ"כ

$$\text{Objective: } \forall i: y_i \beta \alpha^* h(x_i) > 1$$

$\sum_{i=1}^m (h(x_i) \neq y_i)$  (הנחה) מתקיימת

## חלק ב' – שאלות אמריקאיות [24 נק']


בשאלות הבאות סמננו את התשובות המתאימות (לפי ההוראות). בחלק זה אין צורך לכתוב הסברים.

א. [6 נק'] נתון דאטה דו-ממדי עם שלושה תיוגים אפשריים – משולש, מעגל וריבוע.

מפעלים All-vs-All (OVA) עם פרספטורון בטור מסווג בסיס. לכל בעיה ביןארית מרכיבים את הפרספטורון מספיק איטרציות כך שאם הבעיה פרידה ליניארית – הפרספטורון יתכנס (חישבו מה קורה אחרת).

בכל תרשימים מצוירים שלושה גבולות החלטה שאמורים לתאר את הגבולות שהתקבלו ע"י מסווגי הבסיס (הבינאריים).

**הキפו** את האות שמתאימה לתרשים היחיד שמתאר גבולות החלטה שיכולים להתקבל ע"י השיטה שתוארה לעיל.



ב. [6 נק'] נתון דאטה  $d$ -ממדי  $\{(x_i, y_i)\}_{i=1}^m$  עם סיוגים ביןאריים ( $\pm 1$ ). X

סמננו את בל הטענות הנכונות בהכרח ביחס לשיטות להורדת ממד לממד נמוך כלשהו.

הבהרה: זו שאלת חשיבה ולא שאלת טריוויה.

א. הדאטה המקורי פריד ליניארית  $\Leftarrow$  הדאטה פריד ליניארית לאחר הורדת ממד ליניארית עם PCA.

ב. הדאטה המקורי פריד ליניארית  $\Leftarrow$  בהסתברות גבוהה, הדאטה פריד ליניארית לאחר הורדת ממד ליניארית עם Random Projections.


ג. הדאטה המקורי פריד ליניארית  $\Leftarrow$  הדאטה פריד ליניארית לאחר הורדת ממד עם Kernel-PCA (עם קרבנל לא ליניארי).

ד. הדאטה פריד ליניארית לאחר הורדת ממד ליניארית עם PCA  $\Leftarrow$  הדאטה המקורי פריד ליניארית.

ה. PCA היא שיטה Supervised Random Projections בעוד ש- Unsupervised PCA.

ג. [6 נק'] נתונה בעית וגרסיה לינארית (עבור  $\lambda \geq 0, p \in \{0.5, 1, 2\}$ )

$$\operatorname{argmin}_{\mathbf{w}} \left( \frac{1}{m} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_p^p \right) = \operatorname{argmin}_{\mathbf{w}} \left( \frac{1}{m} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_p^p \right)$$



סמןו את כל הטענות הנכונות.

הערה: בכל הסעיפים, שואלים על קמירות ביחס ל- $\mathbf{w}$ .

$$\text{回忆录: } \|\mathbf{w}\|_p^p \triangleq \sum_{k=1}^d |w_k|^p$$

a. כאשר  $0 = \lambda$ : ההסיאן הוא  $\mathbf{X}^\top \mathbf{X}^{\frac{2}{2}}$  שהיא מטריצה PSD אבל לא בהכרח PD, ולכן הבעה לא נכונה קמורה.

b.

כאשר  $0 > \lambda$  וגם  $2 = d$ : הבעה קמורה בהכרחה.

c.

כאשר  $0 > \lambda$  וגם  $1 = d$ : הבעה קמורה בהכרחה.

d.

כאשר  $0 > \lambda$  וגם  $0.5 = d$ : הבעה קמורה בהכרחה.

e.

כאשר  $0 > \lambda$  וגם  $1 = d$ : הבעה אינה גיירה ביחס ל- $\mathbf{w}$  ולכן ניתן להפעיל שיטות גרדינט (או סא-גרדינט).

ד. [6 נק'] רוצים לאמן רשת נוירונים בתצורת Autoencoder.

נסמן את אוסף כל הפרמטרים של הרשת בתרור  $\Theta$ . לכל דוגמה  $\mathbf{x}_i \in \mathbb{R}^d$  נסמן את הפלט של הרשת בתרור  $\hat{\mathbf{x}}_i \in \mathbb{R}^d$ .

$$\operatorname{argmin}_{\Theta} \left( \lambda \|\Theta\|_2^2 + \frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2 \right)$$

בהרצתה ראיינו שנייתן לאמן את הרשת ע"י פיתרון הבעה הבאה:

אילו מבין הביעות הבאות עשויות גם כן להתאים לאימון רשת Autoencoder (עבור  $0 > \lambda$ ?)

סמןו את כל התשובות המתאימות.

$$\operatorname{argmin}_{\Theta} \left( \lambda \|\Theta\|_2^2 + \frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i + \hat{\mathbf{x}}_i\|_2^2 \right) . a$$

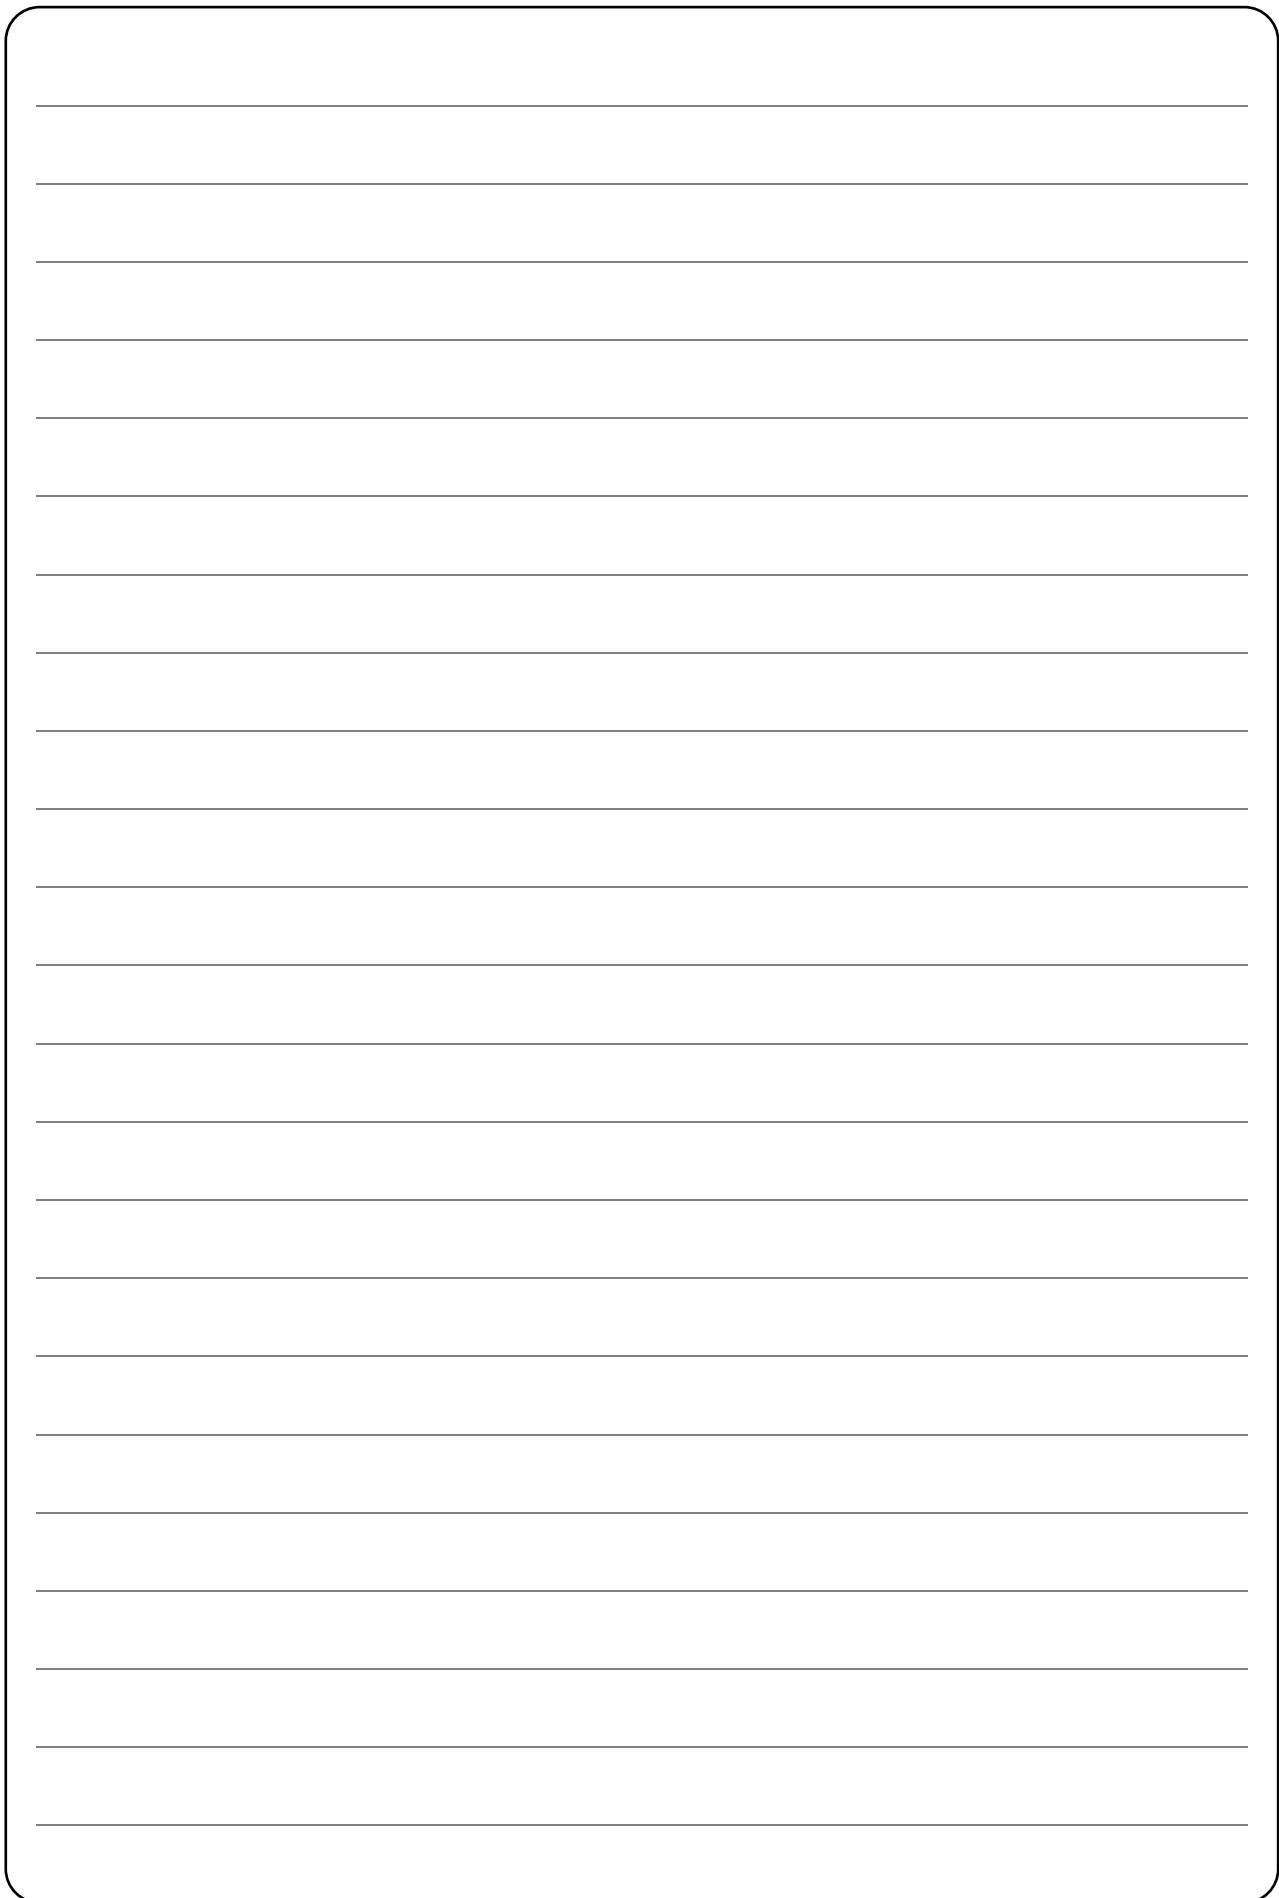
$$\operatorname{argmin}_{\Theta} \left( \lambda \|\Theta\|_2^2 + \frac{1}{m} \sum_{i=1}^m \exp\{\|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2\} \right) . b$$

$$\operatorname{argmin}_{\Theta} \left( \lambda \|\Theta\|_2^2 - \frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i\|_2^2 + \frac{1}{m} \sum_{i=1}^m \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2 \right) . c$$

$$\operatorname{argmin}_{\Theta} \left( \lambda \|\Theta\|_2^2 + \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - \operatorname{sign}(\mathbf{x}_i^\top \hat{\mathbf{x}}_i)\} \right) . d$$


$$\operatorname{argmin}_{\Theta} \left( -\lambda \|\Theta\|_2^2 + \frac{1}{m} \sum_{i=1}^m \frac{\mathbf{x}_i^\top \hat{\mathbf{x}}_i}{\|\mathbf{x}_i\|_2 \|\hat{\mathbf{x}}_i\|_2} \right) . e$$

מסגרת נוספת (יש לציין אם מדובר בטיוטה או בהמשך לשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.

מסגרת נוספת (יש לציין אם מדובר בטيوטה או בהמשך לשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.

מסגרת נוספת (יש לציין אם מדובר בטיוטה או בהמשך לשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.