



מבוא למערכות לומדות (236756)

סמינר אביב תשפ"ב – 23 בספטמבר 2022

מרצה: ד"ר ניר רחנfeld

מבחן מסכם מועד ב'

הנחיות הבחינה:

- **משך הבחינה:** 3 שעות.
- **חומר עזר:** המבחן בחומר סגור (לא ספרים, מחברות, דפי נוסחאות).
- מחשבון: מותר.
- כלים כתיבה: עט בלבד.
- יש לכתוב את התשובות על גבי שאלון זה.
- מותר לענות בעברית או באנגלית.
- קרייאות:
- תשובה בכתב יד לא קרייא – **לא תיבדק**.
- בשאלות רב-ברירה – הקיפו את התשובות בבירור. סימונים לא ברורים יביאו לפסילת התשובה.
- לא יתקבלו ערעורים בנושא.
- במבחן 14 עמודים ממוספרים סה"כ, כולל עמוד שער זה שמספרו 1 ושלושה עמודי טיווח בסוף הגילון.
- נא לכתוב רק את המבוקש ולצף הסבירים קצרים עפ"י ההנחיות.
- **בתום המבחן יש להגיש את שאלון זה בלבד.**

מבנה הבחינה:

- **חלק א' [26 נק']:** 3 שאלות פתוחות.
- **חלק ב' [24 נק']:** 4 שאלות סגורות (אמריקאיות) [כל אחת 6 נק'].

בהצלחה!

חלק א' – שאלות פתוחות [76 נק']



שאלה 1: Multi-Layer Perceptron (MLP) [26 נק']

נתון דатаה דו-ממדי עם סיווגים ביןaries (± 1).

בנייה רשת MLP עם שתי שכבות ליניאריות בתור פונקציה $F: \mathbb{R}^2 \rightarrow (0,1)$ המוגדרת:

$$F(x_1, x_2) = \sigma(w_5 \cdot \text{ReLU}(w_1x_1 + w_2x_2 + b_1) + w_6 \cdot \text{ReLU}(w_3x_1 + w_4x_2 + b_2) + b_3)$$

כאשר $\mathbb{R} \in \mathbb{R}$ הם פרמטרים סקלריים, פונקציית הакטיבציה היא והפלט של הרשת עובר דרך פונקציית הסיגМОיד: $\sigma(z) = \frac{1}{1+\exp\{-z\}}$.



נכין את הרשת לאימון.

נשים לב שהרשת מחזירה הסתברות ובסעיפים הבאים נשתמש ב-loss-negative-log-likelihood המוגדר בתורו:

$$\ell(\underbrace{x}_{\in \{0,1\}^2}, \underbrace{y}_{\in \{0,1\}}) = -y \ln(F(x_1, x_2)) - (1-y) \ln(1 - F(x_1, x_2))$$

א. [2 נק'] חשבו את הנגזרת החלקית $\frac{\partial \ell}{\partial F}$.

תשובה סופית (לרשוטכם טיוטה בסוף הגלילו):

$$\frac{\partial \ell(x, y)}{\partial F} = -y \frac{1}{F(x_1, x_2)} + (1-y) \frac{1}{1 - F(x_1, x_2)}$$

/

ב. [2 נק'] כתבו פונקציה שמהווה subgradient לфункциית ה-ReLU.

תשובה סופית (לרשוטכם טיוטה בסוף הגלילו):

$$\text{ReLU}'(z) = \begin{cases} 0 & , z \leq 0 \\ 1 & , z > 0 \end{cases}$$

לשם הפשטות, נגיד רשותה סימוני עזר:

$$F(x_1, x_2) = \sigma(w_5 \cdot \underbrace{\text{ReLU}(w_1x_1 + w_2x_2 + b_1)}_{\triangleq a_1} + w_6 \cdot \underbrace{\text{ReLU}(w_3x_1 + w_4x_2 + b_2)}_{\triangleq a_2} + b_3) = \sigma(a_3)$$

לשימושכם בהמשך, להלן כמה נגזרות חלקיות מהשכבה הראשונה:

$\frac{\partial a_3}{\partial w_1} = w_5 \cdot \text{ReLU}'(a_1) \cdot x_1$	$\frac{\partial a_3}{\partial w_2} = w_5 \cdot \text{ReLU}'(a_1) \cdot x_2$	$\frac{\partial a_3}{\partial w_3} = w_6 \cdot \text{ReLU}'(a_2) \cdot x_1$	$\frac{\partial a_3}{\partial w_4} = w_6 \cdot \text{ReLU}'(a_2) \cdot x_2$
$\frac{\partial a_3}{\partial b_1} = w_5 \cdot \text{ReLU}'(a_1)$	$\frac{\partial a_3}{\partial b_2} = w_6 \cdot \text{ReLU}'(a_2)$	$\frac{\partial a_3}{\partial b_3}$	$\frac{\partial F}{\partial a_3}$

$\frac{\partial a_3}{\partial w_5} = \text{ReLU}(a_1)$	$\frac{\partial a_3}{\partial w_6} = \text{ReLU}(a_2)$	$\frac{\partial a_3}{\partial b_3} = 1$
--	--	---

ומהשכבה השנייה:

ג. [2 נק'] חשבו את הנגזרת החלקית $\frac{\partial \ell(x, y)}{\partial a_3}$ (שיםו לב שכבר חישבנו את $\frac{\partial \ell}{\partial F}$)
תכונת עזר: הנגזרת של הסיגМОיד היא $\sigma(z)(1 - \sigma(z))$

תשובה סופית:

$$\begin{aligned} \frac{\partial \ell(x, y)}{\partial a_3} &= \frac{\partial \ell}{\partial F} \cdot \frac{\partial F}{\partial a_3} = \left(-\frac{y}{\sigma(a_3)} + \frac{(1-y)}{1-\sigma(a_3)} \right) \cdot \sigma(a_3)(1 - \sigma(a_3)) = \\ &= -y \frac{1}{\sigma(a_3)} + (1-y) \frac{\sigma'(a_3)}{\sigma(a_3)} = \\ &= -y + y \frac{\sigma'(a_3)}{\sigma(a_3)} + \sigma(a_3) - y \frac{\sigma'(a_3)}{\sigma(a_3)} = \sigma(a_3) - y \end{aligned}$$

שני הטעיפים הבאים מדגימים **בעיה** שיכולה לקרות בזמן אימון עם ReLU.

ד. [7 נק'] נתיח שפרמטרים מאוחלים באופן הבא:

נחשב את ערך הפרמטרים אחרי צעד gradient descent ייחיך לדוגמה נתונה (x, y) עם גודל עד 1 = η .

מלאו את התשובות הסופיות בטבלאות.

שים לב: התשובות יכולות להיות תלויות ב- (y, x) אבל לא ב- a_3, a_2, a_1 .

אפשר לחסוך ביטויים כמו $(c)\sigma$ כאשר $c \in \mathbb{R}$ קבוע מפורש, מוביל לחסב את ערכם במחשבון.

First layer

Parameter	Value
w_1	$0 - 0 = 0$
w_2	$0 - 0 = 0$
w_3	$0 - 0 = 0$
w_4	$0 - 0 = 0$
b_1	$-1 - \eta \cdot 0 = -1$
b_2	$-1 - \eta \cdot 0 = -1$

Second layer

Parameter	Value
w_5	$0 - 0 = 0$
w_6	$0 - 0 = 0$
b_3	$-1 - (\sigma(-1) - \eta)$

. [7 נק'] מה יקרה אחרי $T \geq 2$ צעדי גרדינט (לפי אותה דוגמה (y, x) ואותו η)? ענו בקצרה ובאופן איקוני (qualitative).

(o) ויאחן סימן

בנוסף

לפניהם

$$(-1 - (\alpha(-1) - y)) T$$


תשובה סופית (לרשומתכם טיוטה בסוף הגלגול):

בז"ה


וילך וילך

1. [6 נק'] אילו מפונקציות האקטיבציה הבאות ימנעו את הבעיה שהדגmono בעיציפים הקודמים (עבור אתחול זהה)?
סמןו את כל האפשרויות המתאימות.


(A)



(B)



(C)




שאלה 2: מסוגים ליניארים [20 נק']

נתון דאטה d -מנדי $\{(x_i, y_i)\}_{i=1}^m$ עם סיוגים ביןaries (± 1).

א. [10 נק'] נשתמש ב-loss hinge ונדריך את הבעה הקמורה (לא רגולרייזציה):


$$\operatorname{argmin}_{w \in \mathbb{R}^d} \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i w^\top x_i\}$$

ב. עבור דוגמה כלשהי (x_i, y_i) , האם הfonkציית loss hinge מושמת מלמעלה את loss 0-1? נמקו בקצרה.



ב. נתון: הדאטה פריד ליניארית הומוגנית.


הוכחה הפריכו: לבעה שהוגדרה קיים פיתרון אופטימלי כלשהו $w^* \in \mathbb{R}^d$ עם נורמה סופית (משמעות $\|w^*\|_2 < \infty$).



ב. [10 נק'] נשתמש ב-loss Log. ונגידר את הבעה הקמורה (ללא רגולריזציה): $\arg\min_{w \in \mathbb{R}^d} \left\{ \frac{1}{m} \sum_{i=1}^m -\ln \left(\frac{1}{1+\exp\{-y_i w^\top x_i\}} \right) \right\}$

נ. עבור דוגמה כלשהי (x_i, y_i) , האם הפונקציה $\ln \left(\frac{1}{1+\exp\{-y_i w^\top x_i\}} \right)$ – חוסמת מלמעלה את loss-0-1? נמקו בקצרה.

לשימושכם:
תרשים של הפונקציה
 $-\ln(x)$



תשובה וסביר קצר:
 $y_i w^\top x_i = e^{t/4}$
 $-\ln \left(\frac{1}{1+e^{t/4}} \right) = -\ln(0.437) = 0.82$
 סביר לנו ש-0.82 הוא גורם לא-0 ב-0.437
 כ-1-0 הוא גורם לא-0 ב-1 ולכן הטענה נכונה
 מושגנו מ- $f(w)$ כ- $-f(w)$

נ. נתון: הדאטה פריד ליניארית הומוגנית.

הוכחו הטענה: לבעה שהוגדרה קיים פיתרון אופטימלי כלשהו $w^* \in \mathbb{R}^d$ עם נורמה סופית (משמעות $\|w^*\|_2 < \infty$).

תשובה:
 ~~$-\ln \left(\frac{1}{1+e^{-f}} \right) \rightarrow -\ln \left(\frac{1}{1+0} \right) \rightarrow 0$~~
 ~~$-\ln \left(\frac{1}{1+e^f} \right) \rightarrow -\ln \frac{1}{2} \rightarrow 0.693$~~
 אם נקבע w כך ש- $y_i w^\top x_i > 0$ אז $f \rightarrow \infty$
 ~~$-\ln \left(\frac{1}{1+e^{-f(y_i w^\top x_i)}} \right) \xrightarrow{f \rightarrow \infty} 0$~~
 סביר לנו ש- f מוגדר ו- f הפטון (הוילסון) הוא

שאלה 3: Kernel SVM [30 נק']

א. [12 נק'] נתון דאטה d -ממדי $\{(\mathbf{x}_i, y_i)\}_{i=1}^m$ עם סיוגים בינאריים (± 1). נתונה פונקציית Kernel כלשהי $K: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$. צוות מחקר פתר שתי בעיות אופטימיזציה שלמדו:

- (i) Dual Linear SVM לפि the features. נסמן את וקטור המשתנים הדואליים שנלמדו בתור $\alpha \in \mathbb{R}_+^m$.
- (ii) Dual Kernel SVM לפि פונקציית kernel K . נסמן את וקטור המשתנים הדואליים שנלמדו בתור $\alpha' \in \mathbb{R}_+^m$.

נתון שבשני המקרים נמצאו פתרונות שימושים ב- $\log(m)$ וקטורים בתור support vectors (משמע, בכל אחד מהפתרונות α' , α יש בדיק $\log(m)$ כנימות שאינן 0).

בזמן מבחן (לאחר האימון) כשמקבלים דוגמה חדשה לשיווג $\mathbf{x} \in \mathbb{R}^d$, כללי החלטה של המודלים הינם:

Kernel SVM

$$h_{\alpha'}(\mathbf{x}) = \text{sign}\left(\sum_{i=1}^m \alpha'_i y_i K(\mathbf{x}_i, \mathbf{x})\right)$$

Linear SVM

$$h_{\alpha}(\mathbf{x}) = \text{sign}\left(\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^\top \mathbf{x}\right)$$

(i) בזמן המבחן, מה סיבוכיות המקום המינימלית שנדרשת עבור כל ההחלטה של Linear SVM? סמו וסבירו בקצרה.

$\mathcal{O}(m^2)$.e

$\mathcal{O}(\log(m) \cdot d)$.c

$\mathcal{O}(d^2)$.f

$\mathcal{O}(m \cdot d)$.d

$\mathcal{O}(d \cdot m)$.a

$\mathcal{O}(m)$.b

הסבר תמציתי:
בכפל α ו \mathbf{x} נקבל $\alpha_i \mathbf{x}_i$ וכך $\mathbf{x}_i^\top \mathbf{x}$

או כל \mathbf{x}

(ii) בזמן המבחן, מה סיבוכיות המקום המינימלית שנדרשת עבור כל ההחלטה של Kernel SVM (ללא הנחות על הקernel)?

$\mathcal{O}(m^2)$.e

$\mathcal{O}(\log(m) \cdot d)$.c

$\mathcal{O}(d \cdot m)$.a

$\mathcal{O}(d^2)$.f

$\mathcal{O}(m \cdot d)$.d

$\mathcal{O}(m)$.b

הסבר תמציתי:
בליך נארה או ה- α -ים (m מוגבלת)

ולכן $\mathbf{x}_i^\top \mathbf{x}$ מוגבלת

למדנו ש-RBF-Kernel מוגדר בתורה: $\sigma^2 \cdot \exp\left\{-\frac{1}{2\sigma^2} \|\mathbf{u} - \mathbf{v}\|_2^2\right\}$ עבור היפרפרמטר $0 > \sigma^2$. ב. [4 נק'] בעת, נבון את ההתנהגות של כלל החלטה של SVM RBF-Kernel בגבול $\infty \rightarrow \sigma^2$.

ניתן להנify:

- ווקטור המקבדים $\alpha' \in \mathbb{R}_+^m$ הדואליים חסום. משמע, קיים $c_1 > 0$ כך שמתקיים $\|\alpha'\|_2 \leq c_1$.
- הדוגמאות בתפלגות חסומות. משמע, קיים $c_2 > 0$ כך ש- $\forall x \in \mathcal{X}$ מתקיים $\|x\|_2 \leq c_2$.

חשבו את הגבול ($\lim_{\sigma^2 \rightarrow \infty} h_{\alpha'}(\mathbf{x})$)

$$\lim_{\sigma^2 \rightarrow \infty} \text{sign}(\sum_{i=1}^m \alpha'_i y_i K(\mathbf{x}_i, \mathbf{x})) = \text{sign}\left(\lim_{\sigma^2 \rightarrow \infty} (\sum_{i=1}^m \alpha'_i y_i K(\mathbf{x}_i, \mathbf{x}))\right)$$

רמז: כאן הגבול מקיים

$$\begin{aligned}
 &= \text{sign}\left(\lim_{\sigma^2 \rightarrow \infty} \left(\sum_{i=1}^m d'_i y_i e^{\sigma^2}\right)\right) \\
 &= \text{sign}\left(\sum_{i=1}^m d'_i y_i\right) = \text{II}\left(\sum_{y_i=+1}^{d'_i} > \sum_{y_i=-1}^{d'_i}\right)
 \end{aligned}$$

תשובה:

ג. [7 נק'] נתונה התפלגות \mathcal{D} כלשהי על דוגמאות d -ממדיות חסומות (נניח $1 \leq \|x\|_2 \leq \infty$) וסיווגים ביןארים (± 1) מתאימים. וידוע שההתפלגות מאחנת כך שמתקיים $\Pr_{(x,y) \sim \mathcal{D}}[y = 1] = \frac{1}{2}$.

דוגמים 200 דוגמאות אימון ומאמנים עליהם חמשה מדלים שונים. לפיכם טבלה עם תוצאות האימון וה הכללה.

(ה)	(ד)	(ג)	(ב)	(א)	דיקוק / מודל
100%	100%	89%	92%	53%	אימון
84%	23%	50%	89%	50%	הכללה

mbin חמישת המודלים שנלמדו, שניהם הם מודלי RBF-Kernel SVM עם ערכי σ^2 קיצוניים מאוד: $[10^{-6}, 10^6]$.

אילו? יצא הבהרה בזמן הבדיקה שלצורך השאלה, ערכי σ^2 המذוברים שואפים לאינסוף ולאפס).

הנחה: לשם פשוטות, הניחו שבשני המודלים האלה הווקטור הדואלי $\alpha' \in \mathbb{R}_+^m$ שנלמד מקיים $\alpha'_i \in [0.1, 10]$ $\forall i$.

הערות: אנו עוסקים במקרה הסביר ולא במקרים קצה. מדובר בניתוח אנליטי, لكن הניחו שאין שגיאות נומריות.

ן. איזו עמודה מתאימה למודל RBF עם $\sigma^2 = 10^6$?

ן. איזו עמודה מתאימה למודל RBF עם $\sigma^2 = 10^{-6}$?

הסעיף הבא בלתי תלוי בסעיפים הקודמים.

נתונה נקודה $\mathbf{w} \in \mathbb{R}^d$.

$$K(\mathbf{u}, \mathbf{v}) = \frac{1}{2} (\|\mathbf{u} - \mathbf{w}\|^2 + \|\mathbf{v} - \mathbf{w}\|^2 - \|\mathbf{u} - \mathbf{v}\|^2) \text{ בטור } K: (\mathbb{R}^d \times \mathbb{R}^d) \rightarrow \mathbb{R}$$

ד. [7 נק'] הוכיחו שהפונקציה K מהויה קרנל חוקי.

עשוי את ע"י הגדרה ברורה של פונקציית מיפוי p והוכחה שמקיים $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^p$

从中: מומלץ להגדיר מיפוי שמקיים $d = p$

$$\begin{aligned}
 & \cancel{\mathbf{u}^2 - 2\mathbf{u}\mathbf{w} + \mathbf{w}^2} + \cancel{\mathbf{v}^2 - 2\mathbf{v}\mathbf{w} + \mathbf{w}^2} \\
 & \quad \cancel{\mathbf{u}^2 + 2\mathbf{u}\mathbf{v} - \mathbf{v}^2} \\
 K(\mathbf{u}, \mathbf{v}) &= \frac{1}{2} \left((\mathbf{u} - \mathbf{w})^2 + (\mathbf{v} - \mathbf{w})^2 - (\mathbf{u} - \mathbf{v})^2 \right) = \\
 &= \mathbf{w}^2 + \mathbf{u}\mathbf{v} - \mathbf{w}\mathbf{v} - \mathbf{w}\mathbf{u} - \\
 &= \mathbf{u}(\mathbf{v} - \mathbf{w}) + \mathbf{w}(\mathbf{w} - \mathbf{v}) = \\
 &= \mathbf{u}(\mathbf{v} - \mathbf{w}) - \mathbf{w}(\mathbf{v} - \mathbf{u}) = \\
 &= (\mathbf{u} - \mathbf{w})(\mathbf{v} - \mathbf{u})
 \end{aligned}$$

$$\phi(\mathbf{u}) = (\mathbf{u} - \mathbf{w})$$

חלק ב' – שאלות רב-ברירה [24 נק']

בשאלות הבאות סמננו את התשובות המתאימות (לפי ההוראות). בחלק זה אין צורך לכתוב הסברים.

a. [6 נק'] נתונים מרחב דוגמאות $\mathbb{R}^d \subseteq \mathcal{X}$ ומחלקה היפותזות כלשהי \mathcal{H} מעל \mathcal{X} .

בנוסף, נתונה תת-קבוצה $\mathcal{X}' \subseteq \mathcal{X}$.

נגידר את מחלקה היפותזות \mathcal{Q} על ידי **מצומס תחום ההגדרה** של היפותזות ב- \mathcal{H} לתחת-הקבוצה \mathcal{X}' :

$$\mathcal{Q} = \{ q_h \triangleq h|_{\mathcal{X}'} \mid h \in \mathcal{H} \}, \text{ where } q_h(x) = \begin{cases} h(x), & x \in \mathcal{X}' \\ \text{undefined}, & x \notin \mathcal{X}' \end{cases}$$

סמננו את הטענה הנכונה ✓

a. מתקיים בהכרח $\text{VCdim}(\mathcal{H}) > \text{VCdim}(\mathcal{Q}) \geq \text{VCdim}(\mathcal{H})$ ויתכנו מקרים שבהם $\text{VCdim}(\mathcal{Q}) < \text{VCdim}(\mathcal{H})$

b. מתקיים בהכרח $\text{VCdim}(\mathcal{H}) < \text{VCdim}(\mathcal{Q}) \leq \text{VCdim}(\mathcal{H})$ ויתכנו מקרים שבהם $\text{VCdim}(\mathcal{Q}) < \text{VCdim}(\mathcal{H})$

c. מתקיים בהכרח $\text{VCdim}(\mathcal{H}) = \text{VCdim}(\mathcal{Q})$

d. כל הטענות הקודומות שגויות.

g. [6 נק'] סמננו את כל הטענות הנכונות ביחס ל-**Feature selection** ✗

a. שיטות Wrapper (למשל data imputation) יש להפעיל לפני שלב ה-ho

b. שיטות Wrapper (למשל data normalization) יש להפעיל לפני שלב ה-ho

— c. בעיות סיוג: לפני האימון, ניתן להסיר כל פיצ'ר שיש קורלציה 0 בין ה-target variable, מבלי לפגוע

בביצועים של אלגוריתמי למידה על סט האימון.

d. נתון עץ החלטה כלשהו בעומק L (מספר הקשיות המקסימלי מהשורש לעלה כלשהו).


כפי שלמדנו, כל צומת מס'ג לשתי אפשרויות בעזרת threshold על פיצ'ר אחד.

אזי, העץ כולו משתמש לכל היותר ב- $(1 - L)$ פיצ'רים.

e. מאמנים מס'וג AdaBoost עם מס'וג Decision stump כמס'וג בסיס במשך T איטרציות.


אזי, המס'וג "חזק" שמתќבל משתמש לכל היותר ב- T פיצ'רים.

9=1-10



ג. [6 נק'] נתונות שתי פונקציות קמורות $\mathbb{R} \rightarrow \mathcal{C}$: f, g , המוגדרות מעל סט קמור \mathcal{C} .

סמן את כל הטענות הנכונות בהכרח.




a. הפונקציה $h(z) = f(z) + g(z)$ הינה קמורה.

b. הפונקציה $h(z) = \max\{f(z), g(z)\}$ הינה קמורה.

c. הפונקציה $h(z) = \min\{f(z), g(z)\}$ הינה קמורה.

d. הפונקציה $h(z) = f(g(z))$ הינה קמורה.

e. הפונקציה $h(z) = af(z) + b$ הינה קמורה לכל \mathbb{R} .



ד. [6 נק'] נזכר בשתי פונקציות loss שלמדונו:

מגדירים שתי בעיות סיווג לINIARI (עם דאטה זהה):

$$\text{argmin}_{w \in \mathbb{R}^d} \underbrace{\frac{1}{m} \sum_{i=1}^m \ell_{\text{hinge}}(y_i w^\top x_i)}_{\triangleq P_{\text{hinge}}} , \quad \text{argmin}_{w \in \mathbb{R}^d} \underbrace{\frac{1}{m} \sum_{i=1}^m \ell_{\text{ramp}}(y_i w^\top x_i)}_{\triangleq P_{\text{ramp}}}$$

סמן את כל הטענות הנכונות (השאלה עוסקת במקרה הסביר ולא במקרה קצה).

a. הבעה P_{hinge} צפואה להיות יותר רגילה outliers- מאשר הבעה P_{ramp} .


b. הבעה P_{hinge} קמורה ואילו הבעה P_{ramp} אינה קמורה.

c. עבור הבעה P_{hinge} , נקודה בה הנגרת מוגדרת ומתאפסת היא מינימום גלובלי.

d. עבור הבעה P_{ramp} , נקודה בה הנגרת מוגדרת ומתאפסת היא מינימום גלובלי.


e. ערך המינימום הגלובלי של P_{hinge} הוא 0 \Leftrightarrow ערך המינימום הגלובלי של P_{ramp} הוא 0.

מסגרת נוספת (יש לציין אם מדובר בטויטה או בהמשך לשובה אחרת):




A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.

מסגרת נוספת (יש לציין אם מדובר בטויטה או בהמשך לשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.

מסגרת נוספת (יש לציין אם מדובר בטيوת או בהמשך לתשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.