



מבוא למערכות לומדות (236756)

סמסטר חורף תשפ"ג – 15 בפברואר 2023

מרצה: ד"ר יונתן בלינקוב

מבחן מסכם מועד א'

הנחיות הבחינה:

- **משך הבחינה:** שלוש שעות.
- **חומר עזר:** המבחן בחומר סגור (ללא ספרים, מחברות, דפי נוסחאות).
- מחשבון: מותר.
- כלי כתיבה: עט בלבד.
- יש לכתוב את התשובות על גבי שאלון זה.
- מותר לענות בעברית או באנגלית.
- הוכחות והפרכות צריכות להיות פורמליות.
- קריאות:
- תשובה בכתב יד לא קריא – לא תיבדק.
- בשאלות רב-ברירה – הקיפו את התשובות בבירור. סימונים לא ברורים יביאו לפסילת התשובה.
- לא יתקבלו ערעורים בנושא.
- במבחן 17 עמודים ממוספרים סה"כ, כולל עמוד שער זה שמספרו 1 ושלושה עמודי טיוטה בסוף הגיליון.
- נא לכתוב רק את המבוקש ולצרף הסברים קצרים עפ"י ההנחיות.
- **בתום המבחן יש להגיש את שאלון זה בלבד.**

בהצלחה!

חלק א' – שאלות פתוחות [94 נק']

שאלה 1: רגישות של מסווגים לסיבובים [24 נק']

נתון סט אימון דו-ממדי עם תיוגים בינאריים, משמע לכל $i = 1, \dots, m$ מתקיים $\mathbf{x}_i \in \mathbb{R}^2, y_i \in \{-1, 1\}$.

לומדים שני מסווגים:

• בשלב הראשון: לומדים מסווג על סט האימון המקורי ומחשבים עליו את דיוק האימון.


• בשלב השני:

○ מסובבים את כל הדאטה ב- 45° סביב ראשית הצירים (ראו דוגמה).

○ מאמנים מסווג חדש על סט האימון המעודכן,

ומחשבים עליו את דיוק האימון המעודכן.

סיבוב לדוגמה



תזכורת: הסיבוב של הדאטה יכול להתבצע ע"י מיפוי $\mathbf{x}_i \mapsto \mathbf{Q}\mathbf{x}_i$, כאשר $\mathbf{Q} \in \mathbb{R}^{2 \times 2}$ הינה מטריצת סיבוב ממשית,

שהיא מטריצה אורתונורמלית המקיימת $\mathbf{Q}^{-1} = \mathbf{Q}^T$.

עבור כל אלגוריתם למידה, סמנו האם דיוק האימון של המסווג החדש על סט האימון המעודכן זהה בהכרח לזה של המסווג המקורי על סט האימון המקורי.

הסבירו בקצרה את תשובותיכם (2-4 משפטים בכל סעיף).

הניחו שאין צעדים אקראיים או שגיאות נומריות בריצת האלגוריתמים (בעיות קמורות מתכנסות לפתרון האנליטי במדויק).

א. kNN עם $k = 3$ (דוגמה לא נחשבת שכנה של עצמה). דיוק האימון זהה בהכרח? כן / לא

הסבר:

ב. Hard-SVM ליניארי לא הומוגני בהנחה שהדאטה המקורי פריד. דיוק האימון זהה בהכרח? **כן / לא**

הסבר:

ג. AdaBoost with decision stumps, maximum of $T = 10$ iterations. דיוק האימון זהה בהכרח? **כן / לא**

הסבר:

ד. Homogeneous logistic regression with L2 regularization (ללא הנחה שהדאטה המקורי פריד):

$$\operatorname{argmin}_{\mathbf{w} \in \mathbb{R}^2} \sum_i \ln(1 + \exp(-y_i \mathbf{w}^T \mathbf{x}_i)) + \lambda \|\mathbf{w}\|_2^2, \text{ for some } \infty > \lambda > 0$$

דיוק האימון זהה בהכרח? **כן / לא**

הסבר:

שאלה 2: VC-dimension [20 נק']

א. [6 נק'] הוכיחו שלכל מחלקת היפותזות סופית \mathcal{H} מתקיים בהכרח $VCdim(\mathcal{H}) \leq \log_2(|\mathcal{H}|)$.

במז: ניתן להוכיח זאת בשלילה ובקצרה.

הוכחה (לרשותכם דפי טיוטה בסוף הגיליון):

ב. [4 נק'] נגדיר מרחב דוגמאות סופי $\mathcal{X} = \{x_1, x_2\}$ (במרחב יש שתי דוגמאות במרחב כלשהו, לא נבטא במפורש את (x_1, x_2))

ומחלקת היפותזות סופית $\mathcal{H} = \{h_1, h_2\}$, כאשר h_1, h_2 מוגדרות באופן הבא:

	h_1	h_2
x_1	+1	-1
x_2	-1	-1

(המשמעות של הטבלה היא, למשל, שמתקיים $h_1(x_1) = +1$)

ענו: מתקיים $VCdim(\mathcal{H}) =$ הוכיחו את תשובתכם.

הוכחה:

רמז: גם בסעיפים הבאים ניתן להגדיר מרחב דוגמאות סופי $\mathcal{X} = \{x_1, \dots, x_n\}$ ואוסף סופי \mathcal{H} של היפותזות $\{-1, +1\}$ של $h: \mathcal{X} \rightarrow \{-1, +1\}$.

על ההיפותזות להיות שונות (distinct) במובן שאין שתי היפותזות ב- \mathcal{H} שמחזירות פלט זהה על כל הדוגמאות ב- \mathcal{X} .

בשני הסעיפים אין צורך להוכיח את ה-VC-dimension של המחלקות שתציעו.

ג. [5 נק'] הראו מחלקת היפותזות \mathcal{H} עבורה $|\mathcal{H}| = 4$ וגם $\text{VCdim}(\mathcal{H}) = 1$.

תשובה (לרשותכם דפי טיוטה בסוף הגיליון):

ד. [5 נק'] הראו מחלקות היפותזות $\mathcal{H}_1, \mathcal{H}_2$ עבורן $\text{VCdim}(\mathcal{H}_1) = \text{VCdim}(\mathcal{H}_2) = 1$ וגם $\text{VCdim}(\mathcal{H}_1 \cup \mathcal{H}_2) = 3$.

תשובה:

שאלה 3: רגרסיה ליניארית [25 נק']

בשאלה זו מרחב הדוגמאות הוא $\mathcal{X} = \mathbb{R}^d$ ומרחב התיוגים הוא $\mathcal{Y} = \mathbb{R}$.

נתון מדגם $S = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$.

רגרסיה ליניארית המשלבת רגולריזציה מסוג L1 ומסוג L2 נקראת ElasticNet:

$$\mathbf{w}^* \triangleq \operatorname{argmin}_{\mathbf{w} \in \mathbb{R}^d} \left(\underbrace{\sum_{i=1}^m (\mathbf{w}^T \mathbf{x}_i - y_i)^2}_{\mathcal{L}(\mathbf{w}; S)} + \underbrace{\lambda \alpha \|\mathbf{w}\|_2^2 + \lambda(1 - \alpha) \|\mathbf{w}\|_1}_{R_{\lambda, \alpha}(\mathbf{w})} \right)$$

עבור $\lambda \geq 0, \alpha \in [0, 1]$ כלשהם.

א. [5 נק'] בטור הימני יש שלוש השמות של λ, α , שהופכות את הבעיה לעיל לבעיות רגרסיה מוכרות. בטור השמאלי, יש חמש שיטות גנרטיביות. במהלך הקורס ראינו שקילות בין שתי בעיות מימין לשתי שיטות משמאל (תחת הנחות מסוימות על הדאטה). את השקילות השלישית עליכם להסיק לבד. מלאו את המשבצות הריקות של שלוש הבעיות בטור הימני במספרים של שלוש השיטות השקולות להן בטור השמאלי.

i. שערך MLE	<input type="text"/>	a. הבעיה לעיל כאשר $\lambda = 0$
ii. שערך Naïve Bayes	<input type="text"/>	b. הבעיה לעיל כאשר $\lambda > 0, \alpha = 0$
iii. שערך MAP עם Gaussian prior	<input type="text"/>	c. הבעיה לעיל כאשר $\lambda > 0, \alpha = 1$
iv. שערך MAP עם Binomial prior	<input type="text"/>	
v. שערך MAP עם Laplace prior	<input type="text"/>	

מעטה נניח $\lambda > 0, \alpha \in (0, 1)$ בלבד.

ב. [12 נק'] בסעיף זה נניח שיש $d = 2$ פיצ'רים והם **זהים** זה לזה, כלומר $\forall i \in [m]: x_i[1] = x_i[2]$ (וכאמור, $\lambda > 0, \alpha \in (0, 1)$).

(a) לכל $\mathbf{w} = \begin{bmatrix} w[1] \\ w[2] \end{bmatrix} \in \mathbb{R}^2$ נגדיר את $\tilde{\mathbf{w}} = \begin{bmatrix} w[2] \\ w[1] \end{bmatrix}$.

הוכיחו: תחת ההנחות, לכל $\mathbf{w} \in \mathbb{R}^2$ מתקיים $\mathcal{L}(\mathbf{w}; S) + R_{\lambda, \alpha}(\mathbf{w}) = \mathcal{L}(\tilde{\mathbf{w}}; S) + R_{\lambda, \alpha}(\tilde{\mathbf{w}})$.

הוכחה:

טענת עזר: פונקציית הרגולריזציה $R_{\lambda, \alpha}$ היא **קמורה במובן החזק** (strictly convex). משמע, מתקיים באי-שוויון חזק:

$$\forall \mathbf{w}_1 \neq \mathbf{w}_2 \in \mathbb{R}^d, \forall \beta \in (0,1): \beta R_{\lambda,\alpha}(\mathbf{w}_1) + (1-\beta)R_{\lambda,\alpha}(\mathbf{w}_2) > R_{\lambda,\alpha}(\beta \mathbf{w}_1 + (1-\beta)\mathbf{w}_2)$$

משמע, מתקיים: $w^*[1] = w^*[2]$.

This image shows a single sheet of white paper with horizontal ruling lines. The lines are evenly spaced and extend across the width of the page. There are no margins, text, or other markings on the paper.

להלן משפט. **הבינו אותו היטב.** בפרט, השתכנעו שהוא מכליל את שהוכחנו בסעיף הקודם.




משפט: תחת הנחות (לא מגבילות במיוחד) על הנתונים, כל שני מקדמים של פתרון ה-Elastic Net מקיימים:

$$\forall a, b \in [d]: \left(|\mathbf{w}^*[a] - \mathbf{w}^*[b]| \leq \frac{1}{\lambda\alpha} \sqrt{(1 - \rho_{a,b}) \cdot c} \right)$$

כאשר $\rho_{a,b} \triangleq \frac{\text{Cov}(x[a], x[b])}{\sigma_a \sigma_b} \in [-1, 1]$ הוא מקדם המתאם (קורלציה) של פירסון בין הפיצ'רים a, b (על פני כל הדוג') ו- $c > 0$ הוא קבוע כלשהו.

ג. [8 נק'] עבור dataset עם 6 פיצ'רים, אימנו ElasticNet עם ערכי $\alpha \in \{0.01, 0.5, 0.99\}$ וערכי $\lambda > 0$ שונים. כל עקומה בגרפים מראה את ערכיו של מקדם יחיד (מתוך 6) בפתרון שנוצר מצירוף של α (ברמת הגרף) ו- λ (בציר x). נתון: ישנם שני זוגות של פיצ'רים עם קורלציה גבוהה (בכל זוג, קורלציה גבוהה בין שני הפיצ'רים של אותו זוג).

ליד כל גרף סמנו את ערך α המתאים לו ביותר והסבירו בקצרה את בחירותיכם. היעזרו במשפט לעיל בהסברים.




שאלה 4: מסווגים ליניאריים [25 נק']

תזכורת:

כלל החלטה $h: \mathbb{R}^d \rightarrow \{-1, +1\}$ נקרא ליניארי אם ורק אם קיימים $\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}$ כך ש- $h(\mathbf{x}) = \text{sgn}(\mathbf{w}^T \mathbf{x} + b)$ $\forall \mathbf{x} \in \mathbb{R}^d$.

תזכורת: $\sigma(z) = \frac{1}{1+\exp\{-z\}}$



ובפרט מתקיים:

$$\sigma(0) = 0.5, \quad \sigma(1) \approx 0.73, \quad \sigma(2) \approx 0.88, \quad \sigma(3) \approx 0.95$$

$$\sigma(4) \approx 0.98, \quad \sigma(5) \approx 0.99, \quad \sigma(6) \approx 1$$

$$\text{sgn}(z) = \begin{cases} -1, & z \leq 0 \\ +1, & z > 0 \end{cases} \quad \text{נגדיר:}$$

(כך שלא מתקבל אפס לשום קלט)

א. [5 נק'] הוכיחו שכלל ההחלטה של logistic regression (עבור $\mathbf{w}_1 \in \mathbb{R}^d, b_1 \in \mathbb{R}$ כלליים) הוא ליניארי:

$$h_1(\mathbf{x}) = \begin{cases} +1, & \sigma(\mathbf{w}_1^T \mathbf{x} + b_1) > 0.5 \\ -1, & \text{אחרת} \end{cases}$$

הוכחה:

טענות עזר: כלל החלטה ליניארי h צריך לקיים

הפריכּוּן: כלל ההחלטה הבא ליניארי:

במז: כדאי להשתמש בטענת העזר. ניתן לבחור w_3, b_3 ספציפיים כדי להפריך.

הפרכה (לרשותכם דפי טיוטה בסוף הגיליון):

[illegible]

$$.h_2(\mathbf{x}) = \begin{cases} +1, & \sigma(u_2\sigma(\mathbf{w}_2^\top \mathbf{x}) - 1) > 0.5 \\ -1, & \text{אחרת} \end{cases}$$

תשובה:

[illegible]

חלק ב' – שאלה אמריקאית [6 נק']

בשאלה הבאה סמנו את התשובות המתאימות (לפי ההוראות). בחלק זה אין צורך לכתוב הסברים.

א. בתרגילי הבית ראינו איך לבצע tuning על היפר-פרמטרים רבים בעזרת Grid search cross validation.

נתון אלגוריתם למידה \mathcal{A} עם אוסף \mathcal{P} של היפר-פרמטרים שדורשים tuning. נניח שלכל היפר-פרמטר יש בדיוק v ערכים

$\lambda_1, \lambda_2, \dots, \lambda_v$

שנבדקים. נסמן את מספר ה-folds בתהליך ה-CV בתור k ואת מספר דוגמאות האימון בתור m .

100

סמנו את כל הטענות הנכונות בהכרח ביחס לריצה של תהליך ה-Grid search CV:

a. מספר הקריאות ל- \mathcal{A} גדל בצורה ליניארית ב- $|\mathcal{P}|$. ✗

b. מספר הקריאות ל- \mathcal{A} גדל בצורה ליניארית ב- v . ✗

c. מספר הקריאות ל- \mathcal{A} גדל בצורה ליניארית ב- k . ○

d. סיבוכיות זמן הריצה של קריאה בודדת ל- \mathcal{A} גדלה בצורה ליניארית ב- m . ✗

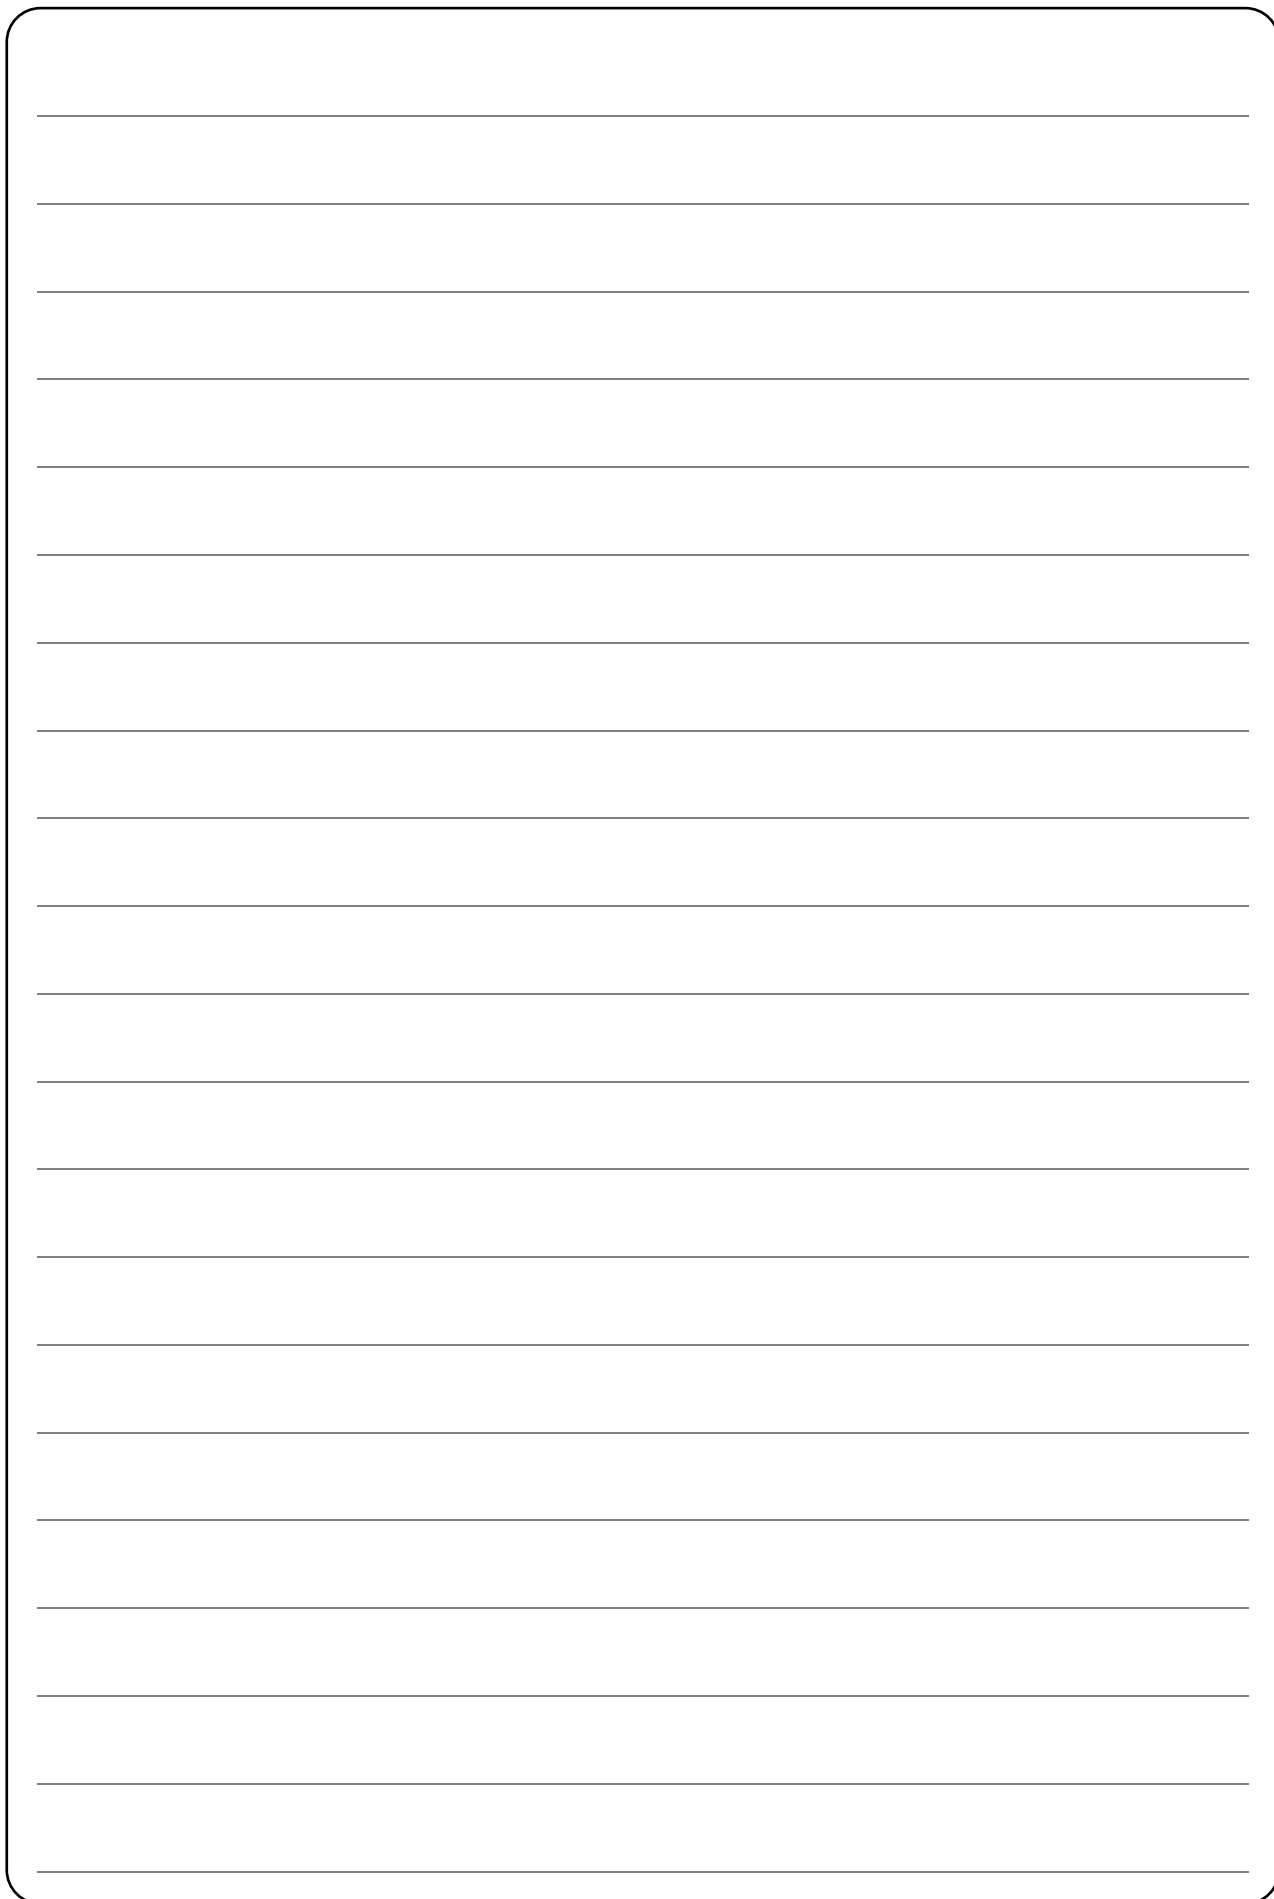
$$A = P \cdot |V| \cdot k$$

$$m(k-1) v^p$$

מסגרת נוספת (יש לציין אם מדובר בטיוטה או בהמשך לתשובה אחרת):

A large rectangular box with rounded corners, containing 25 horizontal lines for writing. The lines are evenly spaced and extend across the width of the box. The box is intended for a student to provide a second answer or clarification if needed.

מסגרת נוספת (יש לציין אם מדובר בטיוטה או בהמשך לתשובה אחרת):

A large rectangular box with rounded corners, containing 25 horizontal lines for writing. The lines are evenly spaced and extend across the width of the box. The box is intended for providing a second answer or clarification.

מסגרת נוספת (יש לציין אם מדובר בטיוטה או בהמשך לתשובה אחרת):

This image shows a single page of white paper with horizontal ruling lines. The lines are evenly spaced and run across the width of the page. There are approximately 20 lines visible. The left edge of the paper has rounded corners. The entire page is blank, with no writing or markings other than the lines themselves.