



## מבוא למערכות לומדות (236756)

סמינר חורף תשפ"ד – 12 באפריל 2024

מרצה: ד"ר יונתן בלינקוב

### מבחן מסכם מועד א'

הנחיות הבחינה:

- **משך הבחינה:** שלוש שעות.
- **חומר עזר:** המבחן בחומר סגור (לא ספרים, מחברות, דפי נוסחאות).
- מחשבון: מותר.
- כל כתיבה: עט  בלבד.
- יש לכתוב את התשובות על גבי שאלון זה.
- מותר לענות בעברית או באנגלית.
- הוכחות והפרוכות צריכות להיות פורמליות.
- קרייאות:
- סימונים לא ברורים בשאלות רב-ברירה ו/או תשבות מילוליות בכתב יד לא קראי יובילו לפסילת התשובה.
- לא יתקבלו ערעורים בנושא.
- בבחן 14 עמודים ממוספרים סה"כ, כולל עמוד שער זה שמספרו 1 ושלושה עמודי טיווח בסוף הגיליון.
- נא לכתוב רק את המבוקש ולצף הסבירים קיצרים עפ"י ההנחיות.
- **בתום המבחן יש להגיש את שאלון זה בלבד.**
- **לזכאים להערכת חלופית מתאפשרת בחירה בין שאלות 3 ו-4.**

**בהצלחה!**

## שאלה 12] Maximum Likelihood Estimation : 1 נק' ✓

נתונות  $m$  דגימות חד-ממדיות  $\{x_1, x_2, \dots, x_m\}$  עבור  $p \in (0,1)$  שנדגמו.  $X \sim \text{Geo}(p)$  משמשתנו מקרי (i.i.d.) מספר ה"ניסוי" ברנולי (הטלות מטבע) בסיכוי  $p$  עד להשגת "הצלחה" אחת.

נכיר שימושה גאומטרי מאפיין את מספר ה"ניסוי" ברנולי (הטלות מטבע) בסיכוי  $p$  עד להשגת "הצלחה" אחת ומואפיין ע"י פונקציית ההסתברות הבאה:

$$\Pr(X = x_i | p) = (1 - p)^{x_i - 1} p$$

שערכו את הparameter  $p$  באמצעות Maximum Likelihood Estimation (estimate).

משמעותו, עליכם לפתח ביטוי עבור  $\hat{p} = \operatorname{argmax}_p L(S; p) = \operatorname{argmax}_p \Pr(x_1, x_2, \dots, x_m; p)$ .

$$\begin{aligned}
 \hat{p} &= \operatorname{argmax}_p L(S; p) = \operatorname{argmax}_p \ln L(S; p) = \operatorname{argmax}_p \ln \Pr(x_1, x_2, \dots, x_m; p) = \\
 &= \operatorname{argmax}_p \ln \prod_{i=1}^m \Pr(x_i; p) = \operatorname{argmax}_p \sum_{i=1}^m \ln \left[ (1-p)^{x_i-1} \cdot p \right] = \\
 &= \operatorname{argmax}_p \sum_{i=1}^m (x_i - 1) \ln(1-p) + \ln(p) \\
 \frac{\partial}{\partial p} &= \sum_{i=1}^m \left( -\frac{x_i - 1}{1-p} + \frac{1}{p} \right) = \frac{m}{p} + \frac{\sum_{i=1}^m 1 - x_i}{1-p} = 0 \Rightarrow \frac{m}{p} + \frac{m}{1-p} = \frac{\sum_{i=1}^m x_i}{1-p} \Rightarrow \frac{m(1-p) + mp}{p(1-p)} = \frac{\sum_{i=1}^m x_i}{1-p} \\
 &\Rightarrow \frac{m}{p(1-p)} = \frac{\sum_{i=1}^m x_i}{1-p} \Rightarrow \frac{1}{p} = \frac{1}{m} \sum_{i=1}^m x_i \Rightarrow \bar{x} = \frac{1}{p} \Rightarrow p = \frac{1}{\bar{x}}
 \end{aligned}$$

## שאלה 2 : VC-dimension of Decision Trees [4 נק']


- א. [4 נק'] להלן הגדירה של "ניתוץ". השמננו מההגדירה את הטעותים.  
השלימו את שלושת הטענות החסרים. בכל מקום כתבו בבירור האם חסר בהגדירה A או E.

$$\mathcal{H} \text{ shatters } C \Leftrightarrow \underbrace{\bigwedge_{\substack{y_1, \dots, y_{|C|} \in \mathcal{Y}: \\ \text{השלימו}}} \exists h \in \mathcal{H}: \underbrace{\bigwedge_{\substack{x_i \in C: \\ \text{השלימו}}} h(x_i) = y_i}_{\text{השלימו}}$$

מעתה והלאה בשאלת זו מרחיב הדוגמאות הוא  $\mathcal{X} = \mathbb{R}$  ומרחב התוצאות הוא  $\mathcal{Y} = \{-1, +1\}$ .

מחלקת ההיפותזות  $\mathcal{H}$  עליה נשאל הינה עצי החלטה מעומק  $1 \leq L$ .

תשובות: עצי ההחלטה בקורס הינם עצים בינאריים בהם הצמתים הפנימיים מתפצלים לפי thresholds. העומק של העץ לא כולל את השורש אבל כן את העליים. לדוגמה, להלן מוצג עץ החלטה "חוקי" מעומק 2.



ב. [10 נק'] עבור עומק כללי  $1 \leq L$ , הוכיחו שהחסם התחתון הוא  $\text{VCdim}(\mathcal{H}) \geq 2^L$ .

הוכחה פורמלית:

$x_1 < x_2 < \dots < x_{2^L}$  סדרה של נקודות על ציר  $x_i$  ו-  $y_1, \dots, y_{2^L}$  סדרה של נקודות על ציר  $y$

לכל  $i = 1, \dots, 2^L$  קיימת נספח (כיוון ש- $x_i$  מוגדר כ- $x_{2^{L-i}}$ ) כך ש- $x_i$  מוגדר כ- $x_{2^{L-i}}$  ו- $y_i$  מוגדר כ- $y_{2^{L-i}}$

לכל  $i = 1, \dots, 2^L$  קיימת נספח (כיוון ש- $x_i$  מוגדר כ- $x_{2^{L-i}}$  ו- $y_i$  מוגדר כ- $y_{2^{L-i}}$ ) כך ש- $x_i$  מוגדר כ- $x_{2^{L-i}}$  ו- $y_i$  מוגדר כ- $y_{2^{L-i}}$

לכל  $i = 1, \dots, 2^L$  קיימת נספח (כיוון ש- $x_i$  מוגדר כ- $x_{2^{L-i}}$  ו- $y_i$  מוגדר כ- $y_{2^{L-i}}$ ) כך ש- $x_i$  מוגדר כ- $x_{2^{L-i}}$  ו- $y_i$  מוגדר כ- $y_{2^{L-i}}$

לכל  $i = 1, \dots, 2^L$  קיימת נספח (כיוון ש- $x_i$  מוגדר כ- $x_{2^{L-i}}$  ו- $y_i$  מוגדר כ- $y_{2^{L-i}}$ ) וכך

לכל  $i = 1, \dots, 2^L$  קיימת נספח (כיוון ש- $x_i$  מוגדר כ- $x_{2^{L-i}}$  ו- $y_i$  מוגדר כ- $y_{2^{L-i}}$ ) וכך

$\text{VCdim}(\mathcal{H}) \geq 2^L$

ג. [10 נק'] עבור עומק כללי  $1 \leq L$ , הוכיחו שהחומר העליון הוא  $L$ .  
 $\text{VCdim}(\mathcal{H}) \leq 2^L$

$$\begin{cases} y_i = +1, & i \geq 0 \\ y_i = -1, & i < 0 \end{cases} \Rightarrow \text{从小到大} \quad x_1 < x_2 < \dots < x_{n+1} \Rightarrow \int_{x_1}^{x_{n+1}}$$

↳  $2^{k_1+1}$  のとき  $\forall i \ h'(x_i) = y_i$  ならば  $g_{j_1} \circ g_{j_2} \circ \dots \circ g_{j_m} \circ h'$  は  $C_1$  の

כרא הערבראי יפה נספַחֲתָה וְבִזְמָנָה זֶה שֶׁבְּלֹא גַּם־בְּלֹא

ג' פ' מילויים של ה


- א' כביכול מודולר Ci (לפחות 10%)
- ב' מילויים מוגבלים (לפחות 5%)
- ג' מילויים מוגבלים (לפחות 5%)

1.  $\exists N \forall i > N \exists j \forall i \neq j \leq N y_i \neq y_j$   $\rightarrow$   $y_i = y_{i+1}$   $\forall i \in \mathbb{N}$

$V_{\text{cav}}(\Delta f) \leq 2^{14} \leq 16384$  if  $\Delta f = 12.5 \text{ kHz}$  The error is  $\pm 1\%$  when  $\Delta f = 12.5 \text{ kHz}$

### שאלה 3 : 32 נק' ] Linear Regression


לזקאים להערכת **חולופית בלבד** (כפי שהוגדרו באתר הקורס): סמן את התיבת הזו אם ברצונכם **לדלג** על שאלה זו. המشكל של שאלות 1,2,4 יתפזר באופן ייחסי על פני 100 נקודות. ניתן לדלג רק על שאלה אחת מתוך שאלות 4,3.




(A)

בתרשים של פניכם מופיע מבחן אימון חד-ממדי  $\mathcal{X} = \mathbb{R}, \mathcal{Y} = \mathbb{R}$ .


א. [ 2 נק' ] לומדים רגסיה לינארית לא הומוגנית (עם Least squares ורגיל) על המדגם הנתון. הקיפו את האות של התרשים שמתאים לכך הרגסיה שנלמד.




(B)




ב. [ 4 נק' ] להלן תרשימי Residual analysis מהסוג שהוצע בהרצאה (שים לב לציר ה- $y$  השוניים). הקיפו את האות של התרשים **היחיד** שמתאים לנוטונים ולכך הרגסיה מהסעיף הקודם.




(A)



(B)



(C)




(D)

נגדיר מחלוקת Thresholded linear regression המאפשרת התאמה של שני קווים וגרסיה נפרדים:

$$\mathcal{H}_1 = \{h_{w_1, b_1, w_2, b_2, \tau} \mid w_1, b_1, w_2, b_2, \tau \in \mathbb{R}\}, \quad \text{where} \quad h_{w_1, b_1, w_2, b_2, \tau}(x) = \begin{cases} w_1 x + b_1, & x < \tau \\ w_2 x + b_2, & x \geq \tau \end{cases}$$

כמו במקרה הילינרי, נגדיר היפומת אופטימלית ב- $\mathcal{H}_1$  בתור היפומת שمبיאה למינימום את MSE על הדאטה.



משמעות שגיאה:  $\min_{w_1, b_1, w_2, b_2, \tau \in \mathbb{R}} \frac{1}{m} \sum_{i=1}^m (h_{w_1, b_1, w_2, b_2, \tau}(x_i) - y_i)^2$

- ג. [2 נק'] ציירו על גבי התרשים שמשמאל היפומת אופטימלית ב- $\mathcal{H}_1$ .  
 זאת שאלת הבנה, לא נדרש בציור רמת דיק של מחשב.)

- ד. [8 נק'] ברשותכם אלגוריתם קופסה שחורה LS המקבל אוסף שירוטי של דוגמאות חד-ממדיות והתיוגים שליהן פוטר את בעיית ה-Least squares הילינארית הלא-הומוגנית הרגילה שלמדו בקורס.  
 עבור דאטה חד-ממדי כללי (ולא רק לדוגמה הנתון בסעיפים הקודמים), הציעו אלגוריתם למידה המוצא פרמטרים  $\tau, w_1, w_2, b_1, b_2$  שמייצגים היפומת אופטימלית ב- $\mathcal{H}_1$ . אין צורך להוכיח את נכונות האלגוריתם.

תשובה:

היפומת אופטימלית ב- $\mathcal{H}_1$  מוגדרת כפונקציית גיבוב מינימלית של פונקציית האפסות  $\ell(x_i, \hat{y}_i) = \max(0, \tau - x_i)$ .

היפומת אופטימלית ב- $\mathcal{H}_1$  מוגדרת כפונקציית גיבוב מינימלית של פונקציית האפסות  $\ell(x_i, \hat{y}_i) = \max(0, x_i - \tau)$ .

כעת, ניצור מחלקה דומה המכילה רק את הפונקציות הרציפות מה- $\mathcal{H}_1$ . נעשה זאת ע"י הגדרת  $\mathcal{H}_2$  עם פרמטריזציה שונה:

$$\mathcal{H}_2 = \{h'_{u_1, c_1 u_2, c_2} \mid u_1, c_1 u_2, c_2 \in \mathbb{R}\}, \text{ where } h'_{u_1, c_1 u_2, c_2}(x) = u_1 \max\{0, x - c_1\} + u_2 x + c_2$$

ה. [8 נק'] הוכחו (מתמטי) שמתקיים  $\mathcal{H}_2 \subseteq \mathcal{H}_1$

הוכחה:  

$$h'_{u_1, c_1 u_2, c_2}(x) = u_1 \max\{0, x - c_1\} + u_2 x + c_2 = \begin{cases} u_2 x + c_2 & x < c_1 \\ u_1 x - u_1 c_1 + u_2 x + c_2 & x \geq c_1 \end{cases}$$

$$= \begin{cases} u_2 x + c_2 & , x < c_1 \\ (u_1 + u_2)x + c_2 - u_1 c_1 , & x \geq c_1 \end{cases}$$

$w_1 = u_1 + u_2, b_1 = c_2 - u_1 c_1, w_2 = u_2, b_2 = c_2, T = c_1$

$$= \begin{cases} w_1 x + b_1 , & x < T \\ w_2 x + b_2 , & x \geq T \end{cases} \Rightarrow h'_{u_1, \dots, c_2} \in \mathcal{H}_1 \Rightarrow \mathcal{H}_2 \subseteq \mathcal{H}_1$$

ג. [8 נק'] נתון דאטה חד-ממדי עם תיוגים רציפים ( $x_i \in \mathbb{R}, y_i \in \mathbb{R}$ ) מחולק באופן אקריא לסט אימון ולסט מבחן.

פותרים את בעיית הרגרסיה על סט האימון ע"י מציאת היפותזות אופטימליות ב- $\mathcal{H}_1$  וב- $\mathcal{H}_2$  (ביחס ל-MSE).

כל שורה בטבלה מתארת תוצאות מתהליך הלמידה המתואר על דאטה נתון כלשהו.

חלק מהשורות מתארות תוצאות אפשריות וחלק מתארות תוצאות בלתי אפשריות.

כל אחת מרבע השורות, סמן אם היא אפשרית או לא.

Optimal hypothesis of $\mathcal{H}_1$		Optimal hypothesis of $\mathcal{H}_2$		
Training MSE	Test MSE	Training MSE	Test MSE	האם אפשרית?
17	55	25	33	כן / לא
17	35	15	37	כן / לא
17	35	42	51	כן / לא
0	11	0	9	כן / לא

## שאלה 4: נושאים שונים בפרשפטرون וב-SVM [32 נק']

לזקאים להערכת חלופית בלבד (כפי שהוגדרו באתר הקורס): סמן את התيبة הזו אם ברצונכם **לדלג** על שאלה זו.   
המשקל של שאלות 1,2,3 יתפזר באופן ייחסי על פני 100 נקודות. ניתן לדלג רק על שאלה אחת מתוך שאלות 4,3.

לפניכם אלגוריתם הפרשפטרון (ההומוגני) המקבל כקלט מודגם אימון  $S = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$ , כאשר  $\mathcal{Y} = \{-1, +1\}$  ו-  $\mathcal{X} = \mathbb{R}^d$ .

```

1      w = 0_d
2      errorFound = True
3
4      for epoch=1 to EPOCHS_NUM:
5          errorFound = False
6
7          for i=1 to m:
8              y_i = sign(w^T x_i)
9
10         if y_i != y_i: y_i w^T x_i < 1
11             w = w + y_i x_i
12             errorFound = True
13
14         if not errorFound:
15             break

```

.Margin Perceptron שקול ל-SGD על  $\sum_i \max\{0, -y_i \mathbf{w}^\top \mathbf{x}_i\}$ . בעת נראה תכונה דומה ל- $\text{Margin Perceptron}$  שקיים שփונקציה  $\ell(\mathbf{w}; \mathbf{x}_i, y_i) = \max\{0, 1 - y_i \mathbf{w}^\top \mathbf{x}_i\}$  קמורה ב- $\mathbf{w}$ . נגידר  $\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}; \mathbf{x}_i, y_i) = \sum_i \ell(\mathbf{w}; \mathbf{x}_i, y_i)$ .

א. [5 נק'] הצעו subgradient של  $\ell$  לפי  $\mathbf{w}$ , משמע,  $\nabla_{\mathbf{w}} \ell(\mathbf{w}; \mathbf{x}_i, y_i)$  (כתבו רק תשובה סופית).

$\nabla_{\mathbf{w}} \begin{cases} 1 - y_i \mathbf{w}^\top \mathbf{x}_i & ; y_i \mathbf{w}^\top \mathbf{x}_i < 1 \\ 0 & ; y_i \mathbf{w}^\top \mathbf{x}_i \geq 1 \end{cases} = \begin{cases} -y_i \mathbf{x}_i & ; y_i \mathbf{w}^\top \mathbf{x}_i < 1 \\ 0 & ; y_i \mathbf{w}^\top \mathbf{x}_i \geq 1 \end{cases}$	תשובה:

ב. [9 נק'] הצעו שינוי נקודתי לאלגוריתם הפספטרון (ציינו את מספרי השורות שמתעדכנות ואת השינויים הנדרשים) כך שהאלגוריתם המעודכן יהיה שקול ל-SGD על  $\mathcal{L}(\mathbf{w})$  שהגדנו. יש להסביר בקצרה כיצד השקלות מתקיימת.

$\mathbf{w} = \mathbf{w} + \sum_i y_i \mathbf{x}_i = \begin{cases} \mathbf{w} + y_i \mathbf{x}_i & ; y_i \mathbf{w}^\top \mathbf{x}_i < 1 \\ \mathbf{w} + 0 & ; y_i \mathbf{w}^\top \mathbf{x}_i \geq 1 \end{cases} =$ $= \mathbf{w} + \begin{cases} y_i \mathbf{x}_i & ; y_i \mathbf{w}^\top \mathbf{x}_i < 1 \\ 0 & ; y_i \mathbf{w}^\top \mathbf{x}_i \geq 1 \end{cases} = \mathbf{w} - \begin{cases} -y_i \mathbf{x}_i & ; y_i \mathbf{w}^\top \mathbf{x}_i < 1 \\ 0 & ; y_i \mathbf{w}^\top \mathbf{x}_i \geq 1 \end{cases} = \mathbf{w} - \underbrace{\sum_i h_i \mathbf{x}_i}_{SGD} \ell(\mathbf{w})$	תשובה:

שימו לב: ניתן לענות על השעיפים הבאים גם מבליל לפתרור את השעיפים הקודמים.

**ללא תלות בסעיפים הקודמים, נחזור לעסוק באלגוריתם הפסופטロン הרגיל כפי שמצוין בתחילת השאלה.**

משפט ההתקנות של הפסופטרון:

הידיעה פריד לינארית הומוגנית  $\{(x_i, y_i)\}_{i=1}^m = S$ . נסמן את הנורמה המרבית של דוגמה ע"י  $R \triangleq \max_i \|x_i\|_2$  (סקלר).  
 $w_{SVM} \triangleq \operatorname{argmin}_{w \in \mathbb{R}^d} \|w\|_2$  s.t.  $\forall i: y_i w^\top x_i \geq 1$ ,  
 ishi SVM פיתרון ה-SVM Hard על הדעתה, משמע:  
 אזי, אלגוריתם הפסופטロン יעשה לכל היותר  $(R \|w_{SVM}\|_2)^2$  טוויות חייזי בזמן האימון שלו.

- ג. [9 נק'] נתון דатаה  $S = \{(x_i, y_i)\}_{i=1}^{100}$  פריד לינארית הומוגנית ש"הבטחת" המשפט עבורו הינה 10  
 יוצרים דאטה חדש ע"י הכפלת כל הדוגמאות ב-2, משמע  $S' = \{(2x_i, y_i)\}_{i=1}^{100}$   
 מהי הבטחת המשפט לדאטה החדש? משמע, כמה טוויות חייזי (לכל היותר) יעשה אלגוריתם הפסופטון על הדאטה החדש? כתבו ערך מספר מפורש והסבירו בקצרה את תשובתכם.

תשובות:

$$W_{SVM} = \operatorname{argmin}_w \|w\|_2 \text{ s.t. } \forall i: y_i w^\top x_i \geq 1$$


$$y_i (2w^\top) x_i \geq 1$$

$$w^* = \frac{1}{2} w_{SVM} \quad (2R \cdot \|\frac{1}{2} w_{SVM}\|_2)^2 = (R \|w_{SVM}\|_2)^2 = 10$$

$$R^* = 2R$$

- ד. [9 נק'] נתון דטה  $S = \{(x_i, y_i)\}_{i=1}^{100}$  פריד לינארית הומוגנית ש"הבטחת" המשפט עבורו הינה 10  
 נסיר את הדוגמה האחרון ונקבל דאטה חדש  $S' = \{(x_i, y_i)\}_{i=1}^{99}$ . נסמן את החסם המעודכן בעזרת  $(R' \cdot \|w'_{SVM}\|_2)^2$   
 בטענה שלפניכם, כתבו את היחס ( $=, \leq, \geq$ ) המדויק ביוותר כך שתהייה נכונה בבקרה:  $10 \leq R' \cdot \|w'_{SVM}\|_2 \leq 10$  השלימו

הסבירו בקצרה:



א) הוגזו תגה' בכו רואלה  $\Rightarrow m < 10 < R' < R$   $\Rightarrow$   $R' < R$   $\Rightarrow$   $m < 10 < R'$

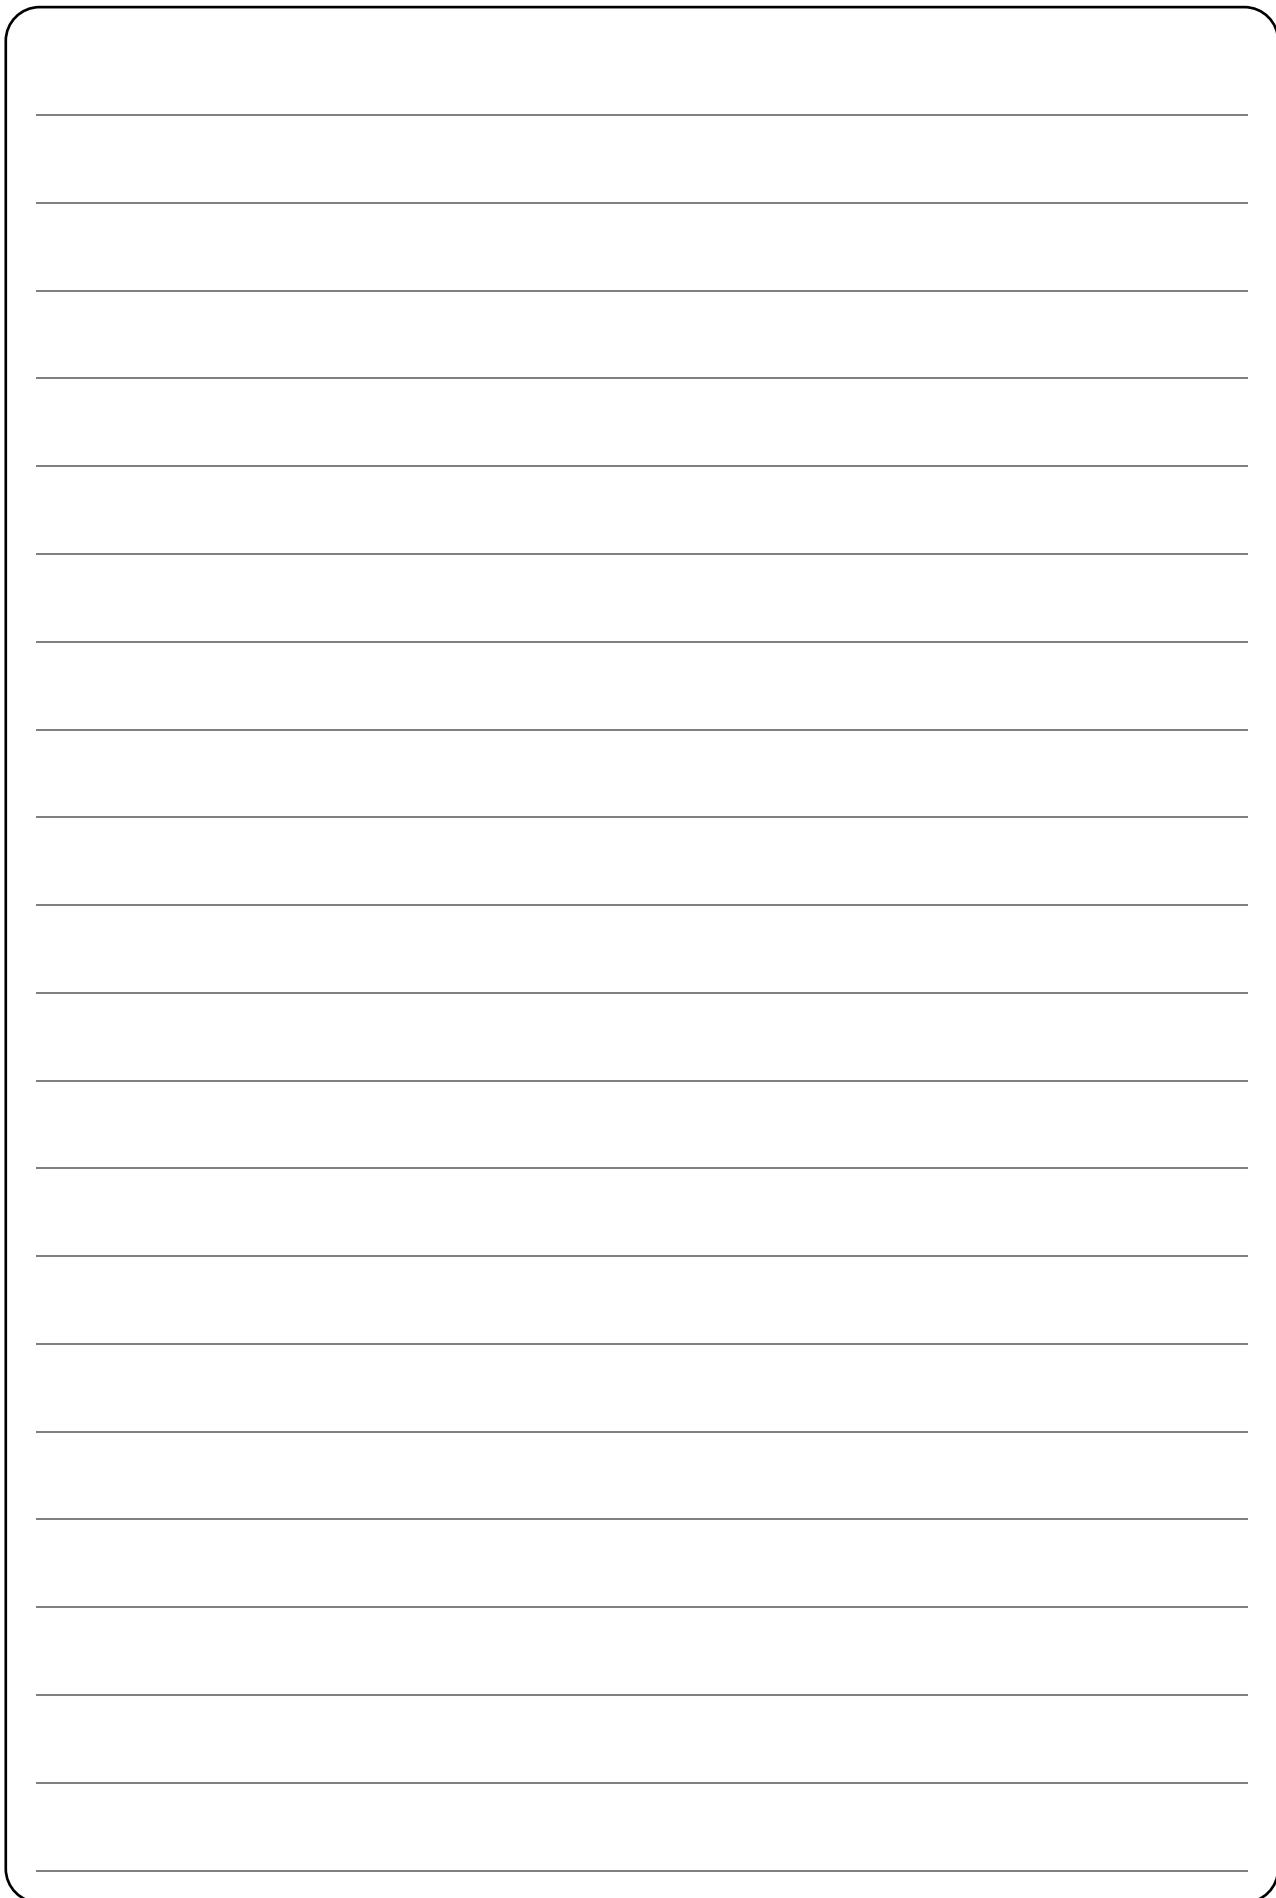
ב) מתרבע נק' קיימת  $\Rightarrow$  מתרבע נק' קיימת  $\Rightarrow$  מתרבע נק' קיימת  $\Rightarrow$   $R' < R$

ג) מתרבע נק' קיימת  $\Rightarrow$  מתרבע נק' קיימת  $\Rightarrow$  מתרבע נק' קיימת  $\Rightarrow$   $R' < R$

ד) מתרבע נק' קיימת  $\Rightarrow$  מתרבע נק' קיימת  $\Rightarrow$  מתרבע נק' קיימת  $\Rightarrow$   $R' < R$


ה) כראין גנטור ה- $m$  תם גויה זו, מוגבר נט' רק  $\Rightarrow$  גנטור נט' פועל

מסגרת נוספת (יש לציין אם מדובר בטيوטה או בהמשך לתשובה אחרת):



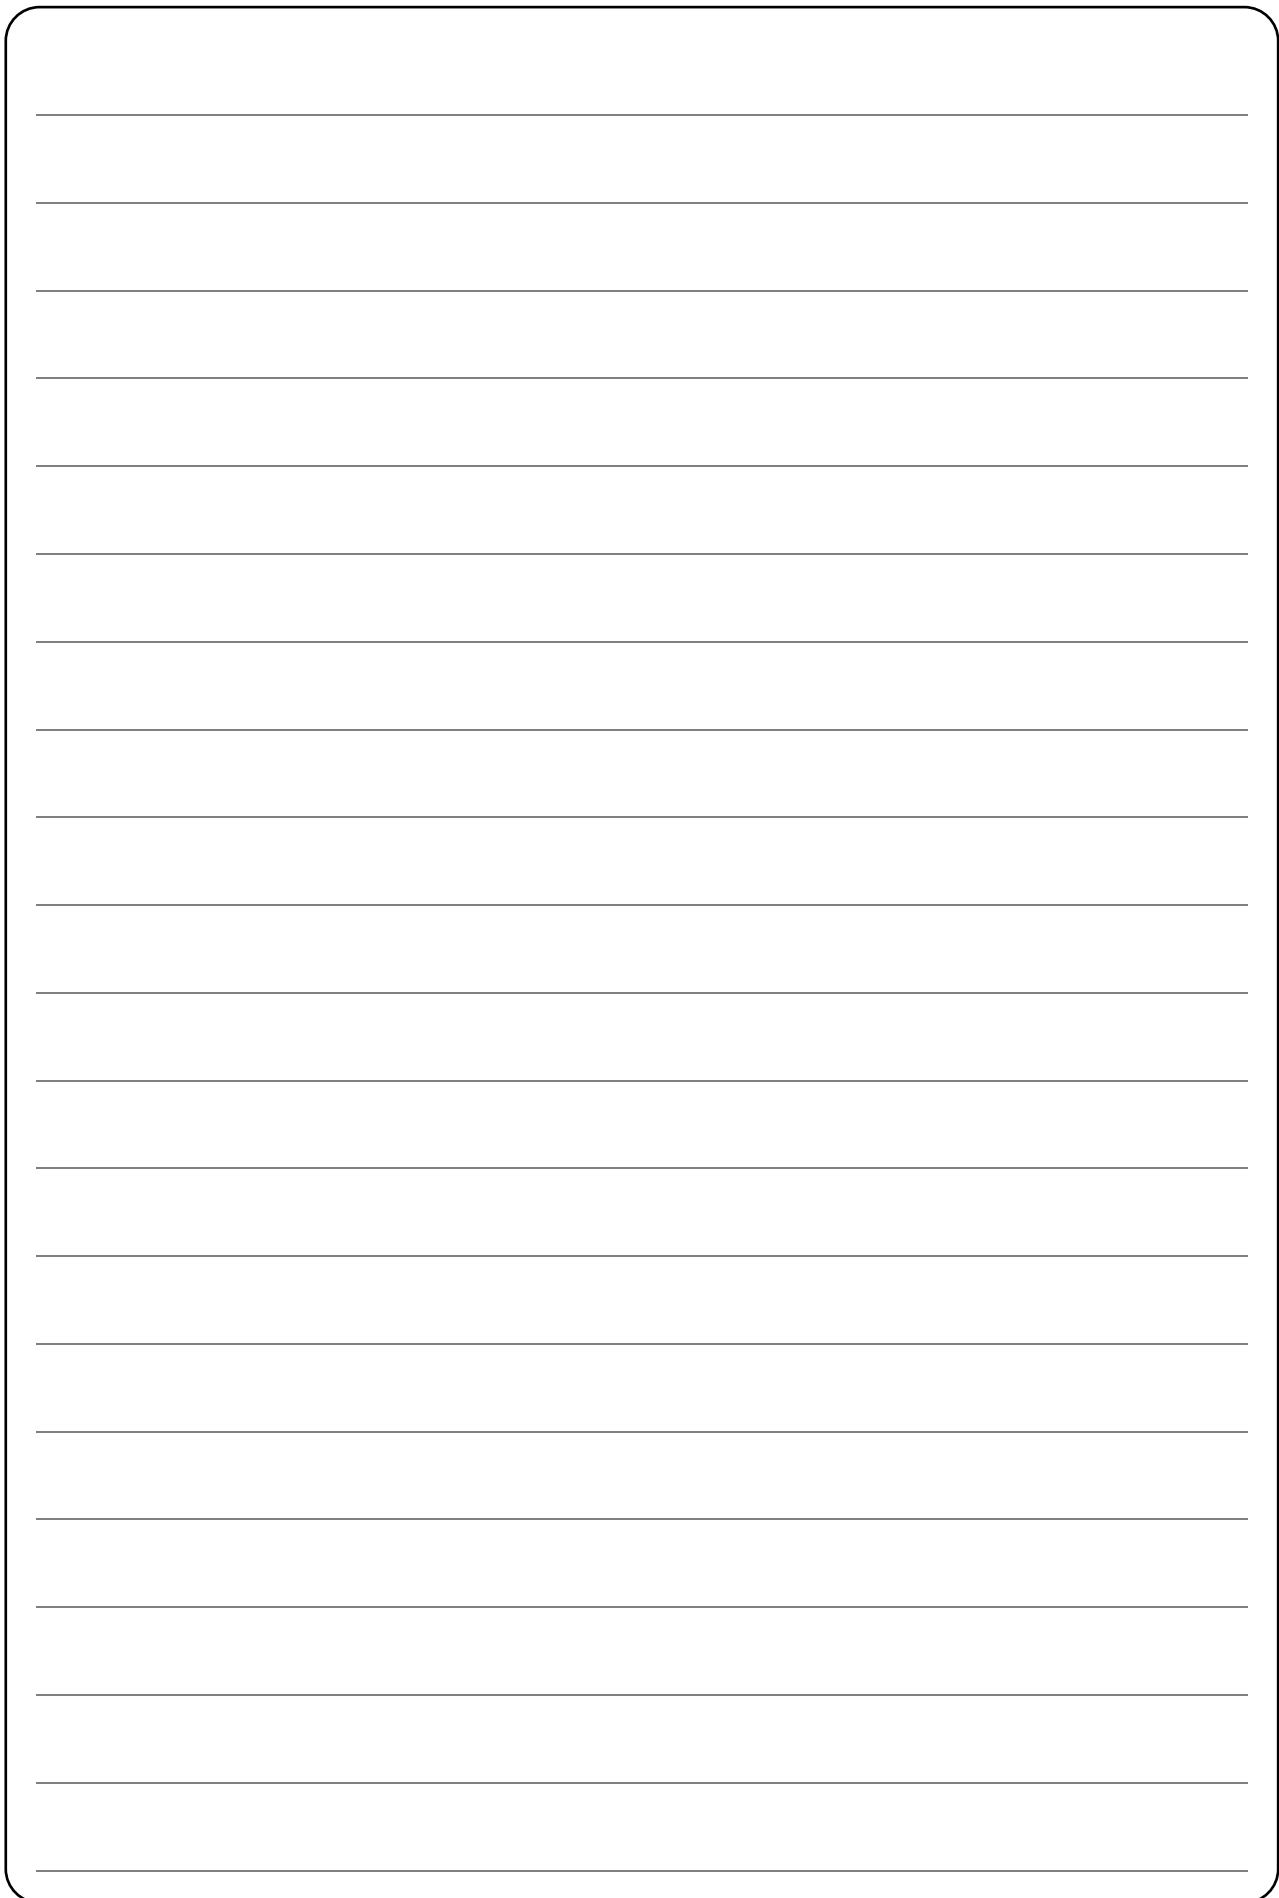
A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.

מסגרת נוספת (יש לציין אם מדובר בטעיטה או בהמשך לשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.

מסגרת נוספת (יש לציין אם מדובר בטيوטה או בהמשך לתשובה אחרת):



A large rectangular frame with rounded corners, containing 20 horizontal lines spaced evenly apart, intended for handwritten responses.